



上海大学

# 毕业论文（设计）

题目：基于深度学习的大规模故障诊断技术研究

学    院：机电工程与自动化学院

专    业：自动化

学    号：18122478

学生姓名：林梓豪

指导教师：修贤超

起讫日期：2022.2.20—2022.5.29

上海大学



SHANGHAI UNIVERSITY

# 毕业论文（设计）

UNDERGRADUATE THESIS (PROJECT)

题目：基于深度学习的大规模故障诊断技术研究

学 院 机电工程与自动化学院

专 业 自动化

学 号 18122478

学生姓名 林梓豪

指导教师 修贤超

起讫日期 2022. 2. 20-2022. 5. 29

---

# 目 录

摘 要.....	III
ABSTRACT.....	IV
第 1 章 绪论.....	1
1.1 故障诊断的意义.....	1
1.2 故障诊断技术概述.....	2
1.2.1 定性分析.....	3
1.2.2 定量分析.....	5
1.3 基于深度学习的故障诊断研究现状.....	7
1.4 论文研究内容和整体结构.....	9
第 2 章 基于深度学习的故障诊断技术研究.....	10
2.1 卷积神经网络概述.....	10
2.2 基于一维卷积神经网络的故障诊断方法.....	13
2.2.1 一维卷积神经网络.....	13
2.2.2 基于一维卷积神经网络的故障分类能力分析.....	15
2.3 基于 AlexNet 卷积神经网络的故障诊断方法.....	19
2.3.1 AlexNet 卷积神经网络.....	19
2.3.2 基于 AlexNet 卷积神经网络的故障分类能力分析.....	21
2.4 基于 GoogleNet 卷积神经网络的故障诊断方法.....	25
2.4.1 GoogleNet 卷积神经网络.....	25
2.4.2 基于 GoogleNet 卷积神经网络的故障分类能力分析.....	26
2.5 本章小结.....	30
第 3 章 基于小波包分解与卷积神经网络的故障诊断技术研究.....	32
3.1 小波包分解概述.....	32
3.2 基于小波包分解与卷积神经网络的故障分类能力分析.....	33
3.2.1 基于小波包分解与 AlexNet 的故障分类能力分析.....	33
3.2.1 基于小波包分解与 GoogleNet 的故障分类能力分析.....	36
3.3 本章小结.....	38

---

<b>第 4 章 基于 LSTM 神经网络的故障预测技术研究 .....</b>	<b>40</b>
4.1 LSTM 神经网络概述.....	40
4.2 基于 LSTM 神经网络的故障预测能力分析 .....	43
4.3 基于 LSTM 神经网络和卷积神经网络的故障预测能力分析 .....	45
4.4 本章小结.....	47
<b>第 5 章 总结与展望.....</b>	<b>49</b>
5.1 主要工作总结.....	49
5.2 未来工作展望.....	50
<b>致 谢.....</b>	<b>51</b>
<b>参考文献 .....</b>	<b>52</b>

---

## 摘要

当今的社会正处于高速发展阶段，世界的工业化程度不断提高。随着现代工业系统趋向于大规模化，工业生产能够满足人们更丰富需求的同时，工业故障发生的几率也在逐渐上升，并可能导致严重的后果。因此故障诊断对于工业生产的安全和效率十分重要，故障诊断技术已经成为工业界和学术界的研究热点。本文针对故障诊断问题，探讨了基于深度学习的故障诊断方法，以正确分类和预测所选数据集为导向，设计了多个神经网络模型，主要工作如下：

（1）针对故障诊断分类问题，采用深度学习中的卷积神经网络作为故障特征提取工具。根据故障数据的形式，分别以一维、AlexNet 和 GoogleNet 卷积神经网络为基础，构建了三种卷积神经网络模型，对模型进行故障分类验证实验，实现了有效的故障分类。同时为了进一步提高故障分类效果，讨论了 GoogleNet 中的核心模块对于故障分类结果的影响。

（2）针对故障分类中特征提取问题，采用传统信号分析中的小波包分解法作为数据预处理的方法，对原始的故障数据进行分解。根据分解后的数据形式，分别以 AlexNet 和 GoogleNet 卷积神经网络为基础，构建了两种卷积神经网络模型。对模型进行故障分类验证实验，两种模型均有效地提取了故障的特征，实现了准确的故障分类。同时通过将原始数据与小波包处理的数据进行测试对比，验证了信号分析方法能够提高故障分类中特征提取的效果。

（3）针对传统故障预测手段效果欠佳问题，采用 LSTM 神经网络对故障进行预测。根据故障时序信号的形式，构建了 LSTM 神经网络对轴承状态进行预测，得到了高精度的预测结果。同时为了进一步提高故障预测效果，提出了将 CNN 与 LSTM 网络结合的方式，得到了较单独使用 LSTM 更高的预测精度。

**关键字：**故障诊断；故障预测；深度学习；神经网络

---

# ABSTRACT

Society is in the stage of rapid development nowadays, and the degree of world industrialization continues to improve. As the modern industrial system tends to be large-scale, while industrial production can meet people's richer needs, the probability of industrial failure is also gradually increasing, which may lead to serious consequences. Therefore, fault diagnosis is very important for the safety and efficiency of industrial production. Fault diagnosis technology has become a research hotspot in industry and academia. Aiming at the problem of fault diagnosis, this thesis discusses the fault diagnosis method based on deep learning, and designs several neural network models to correctly classify and predict the selected data set. The main work is as follows:

(1) Aiming at the problem of fault diagnosis and classification, the convolution neural network in deep learning is used as the fault feature extraction tool. According to the form of fault data, based on one-dimensional, AlexNet and GoogleNet convolutional neural networks, three convolutional neural network models are constructed. The model is verified by fault classification experiment, and effective fault classification is realized. At the same time, in order to further improve the effect of fault classification, the influence of the core module in GoogleNet on the result of fault classification is discussed.

(2) Aiming at the feature extraction problem in fault classification, the wavelet packet decomposition method in traditional signal analysis is adopted as the data preprocessing method to decompose the original fault data. Based on AlexNet and GoogleNet convolutional neural network, two models are constructed according to the decomposed data form. The fault classification verification experiments are carried out for the two models, and the fault characteristics are extracted effectively and the fault classification is achieved accurately. At the same time, by testing and comparing the original data with the data processed by wavelet packet, it is verified that the signal analysis method can improve the effect of feature extraction in fault

---

classification.

(3) In view of the poor effect of traditional fault prediction methods, the circulating neural network is used to predict the fault. According to the selected fault signals, the LSTM neural network model was built to predict the bearing status, and the high-precision prediction results were obtained. Aiming at the problem of feature extraction, the combination of CNN and LSTM network was proposed, and the prediction accuracy was higher than that of LSTM alone.

**Key words:** Fault diagnosis; Fault prediction; Deep learning; Neural networks

---

# 第 1 章 绪论

本章介绍了本课题的研究背景、意义与研究现状，并对本文的主要研究内容和整体结构进行了概述。

## 1.1 故障诊断的意义

随着当今社会和科技的不断进步，现代工业系统的规模向着大型化、复杂化和自动化的趋势发展。与此同时，现代工业设备趋向于智能和复杂，各个部件之间的联系也愈加的紧密。这些变化带来了工业水平的上升，满足了更加精细的工业需求，但同时也导致了工业故障发生的几率不断增加。

大规模工业的故障不仅会导致工业流程的停止，造成严重的经济损失，还可能威胁人们的生命安全，造成十分严重的后果。例如，2005 年 11 月 13 日，吉林石化双苯厂发生爆炸，造成 70 人受伤、6 人失踪；2014 年 8 月 2 日，江苏苏州某公司车间发生重大铝粉尘爆炸事故，造成 163 人受伤、97 人死亡，经济损失高达 3.51 亿元；2018 年 11 月 28 日，张家口发生爆燃事故，造成 24 人死亡、22 人受伤，直接经济损失达 4148.8606 万元<sup>[1]</sup>，如图 1.1 所示；2021 年 2 月 8 日，辽宁康缘华威药业有限公司发生爆炸事故，造成 5 人受伤，其中 2 名重伤人员经抢救无效死亡。



图 1.1 工业故障事故现场



---

由于大规模工业故障可能会带来严重的后果，故障诊断技术已成为当前世界过程控制领域的研究热点，在全生命周期管理占据重要地位。系统是否可靠与安全正逐渐成为设计和评价一个系统的关键指标，同时故障诊断技术能够释放人类劳动力，自动收集并识别工业设备的健康状态<sup>[2]</sup>。因此故障诊断技术需要匹配智能制造的升级而进行同步的提升，实现提高工业生产的安全性、降低工业过程的维护成本、减少非计划性的生产线停工检修时间的目标<sup>[3]</sup>。针对这类目标，故障诊断技术需要通过对设备使用建模、专家系统及人工智能技术的手段，来对运行设备进行状态监测与故障诊断。因此深入研究适合于机械设备发展趋势的故障诊断方法并提供可靠、精准、实时的设备状况对于现代化制造模式具有非常重要的意义<sup>[4]</sup>。

## 1.2 故障诊断技术概述

故障诊断是当前国际过程控制领域的研究热点之一，是保证安全生产的必要手段。故障诊断的目的是利用各种测试办法，对系统中出现的故障进行检测和辨别，确定故障的类型和发生的大致位置，同时对故障进行相应的处理并给出合理的故障预测和预防策略。大体上说，故障诊断和预测技术的发展主要分为三个阶段。

第一阶段：工业设备的组成和结构比较简单，人们没有足够的测量手段来获得设备运行中的各项参数指标。此时的故障诊断主要是凭借工作者过往的经验和知识，通过人工的方式进行，对于复杂故障的诊断效果比较差。

第二阶段：传感器在工业中的广泛使用收集了大量的设备数据和指标，加上计算机技术的不断发展，故障诊断从人工的方式向自动化发展，诊断的效果和精度大幅度提高。虽然不再需要人们进行大量运算，但是在故障的分析决策上还需要人们通过经验来设立规则。

第三阶段：数据挖掘和人工智能技术得到了飞速的发展，深度学习算法的进一步激发了业界和学术界对智能诊断的兴趣<sup>[5]</sup>。传统的依靠经验和专家知识为主的故障诊断方法逐步被淘汰，取而代之的是通过特征提取以及人工智能方法中所得知识为主的方法。故障诊断的效率得到了极大的提升，这更进一步减轻了技术人员的工作压力。进入 21 世纪以来，对于系统装备等的检测和维护技术成为了

研究的主流，故障预测和健康管理的概念因此而诞生。在复杂的系统中，对于其性能发展的趋势、衰减速率的检测能对故障出现的时间进行预测。故障预测技术能对系统各部件的剩余有效寿命进行预测，这对于保障和维护整体系统、增强系统稳定性都有着突出的效用。在智能诊断阶段的基础之上，设备的智能化和网络传输能力的提升使得系统的管理效能更高，同时深度学习等方法的研究进展也使故障诊断与预测真正进入了智能时代。

故障诊断方法目前主要分为定性分析方法和定量分析方法，如图 1.2 所示。

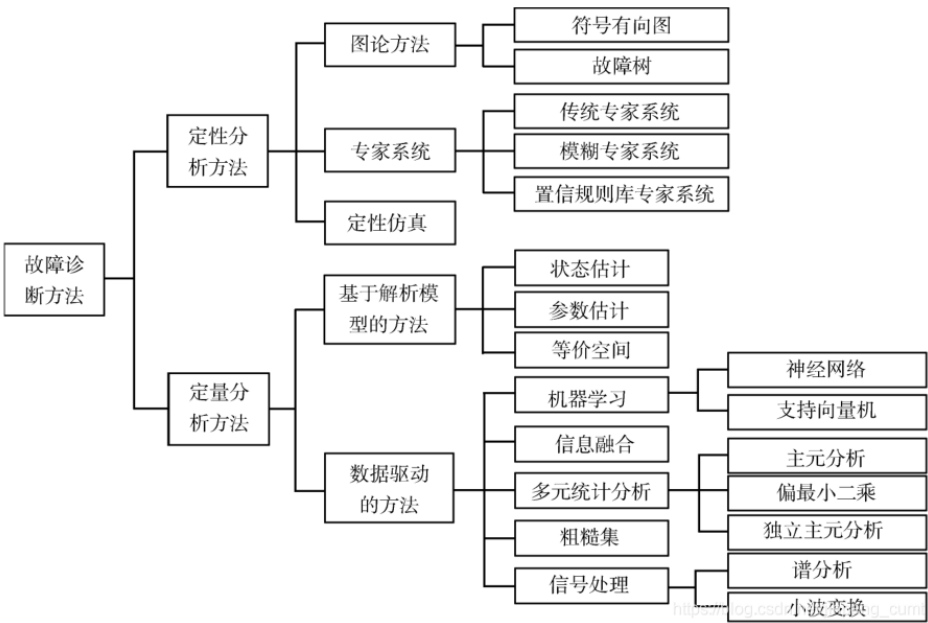


图 1.2 故障诊断方法

1.2.1 定性分析

定性分析方法主要依靠专家知识和实际生产或测试中获得的经验，利用这些人为总结的知识系统对设备进行状态分析和故障诊断。该类方法对于系统模型难以建立，同时在面对具备一定知识和累积经验的情形时更为适用。

(1) 图论方法

图论分析方法主要包括符号有向图(signed directed graph, SDG)方法和故障树分析(fault tree analysis, FTA)方法。SDG 通常情况下被用于描述系统的因果关系，例如在文献[6]中使用 SDG 模型对核动力二回路系统实现了故障诊断。FTA 是一种特殊的逻辑图，是将系统的各模式及故障进行分析后，形成多层的树形结

构，来查明故障发生的原因和概率以及造成的影响，在文献[7]中利用故障树技术实现了铁路通信光缆的故障诊断。

图论分析方法的优点包括建模与结果易于理解和适用情况多等，但是当处理复杂的系统时，该方法正确诊断率不高，难以获得有效的故障诊断结果。

### (2) 专家系统

专家系统通常是利用技术人员在复杂系统实际运转维护中获得的经验以及系统在设计中已知的指标特性等内容，建立一套模拟领域专家进行决策的智能诊断系统，如图 1.3 所示。近年来人工智能的研究成果带动了专家系统方法的发展，通过知识和规则的故障诊断能够直接且明确地解决复杂系统的监视及运行维护工作，在实际应用中也显示了其强大的作用。例如，文献[8]中介绍了一个能实现实时监测全过程的大坝安全管理专家系统，可以识别水电站数据异常，对大坝的安全状态给出评价。

但是，基于专家系统的诊断方法也有着明显的不足，主要表现在：1) 难以获得大量的专业知识；2) 诊断的准确程度过度依赖于数据库中专家经验的数量和质量，而且专家的领域知识有时很难提炼成规则；3) 专家系统的扩展能力存在缺陷，当规则复杂时决策过程会产生矛盾点，使得故障推理效率不高。

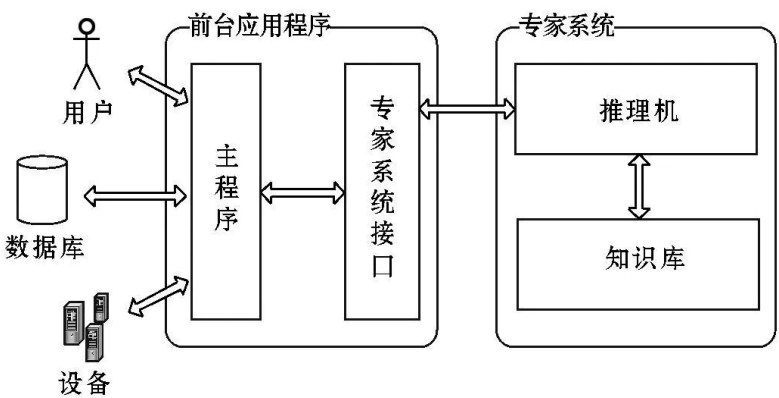


图 1.3 专家系统

### (3) 定性仿真

定性仿真能够定性地对系统进行描述，故障诊断领域中可以使用各种故障情况下的定性描述建立起定性模型。定性仿真可以将系统构造成一组物理符号和反映符号间彼此联系的约束方程，由初始状态作为起点，产生多个可能的后续结果，将异常的结果进行筛除，当没有新状态出现时仿真停止。定性仿真的优点是

可以对动态行为进行推理和学习，文献[9]中提出了一种改进的定性仿真故障诊断方法，通过提取测量值的动态趋势建立模型，对电厂离心压缩机实现了故障诊断，但是定性仿真在面对未知的故障时往往无法实现精确的诊断。

### 1.2.2 定量分析

定量分析是通过准确可靠的对象数量特征和关系，对各项指标进行统计分析。在故障诊断领域中对故障对象建立起准确的数学模型来对故障进行检测和分析，本小节选取几个重要的定量分析方法进行介绍。

#### (1) 解析模型

对于系统或设备的结构和模型较为明确的情况，基于解析模型的方法能够观测输入输出信号差，将实际情况与期望情况进行对比分析，在故障诊断中能够取得不错的效果。一般的设备在设计中有着系统的结构性，如车辆、航天器等等都有着可靠的模型，均包含明确的物理意义。另外在一些系统中可以通过系统识别的方法取得近似的模型(如图 1.4 所示)，这些模型都可以直接进行故障的诊断，且有着很高的效率。例如，文献[10]基于解析模型实现了飞控系统的控制、管理和故障诊断功能，文献[11]提出了一种分阶段的电网故障诊断解析模型，能快速准确诊断故障元件。

由于系统模型的数学意义清晰，基于模型的故障诊断方法效果一般较好，但实际诊断的效果很大程度上依靠模型的准确度，而精准的数学模型往往难以构造。对于复杂系统，其内部可能存在着无法全面掌握的耦合关系，模型的可靠性下降，会严重影响故障诊断的精确度。

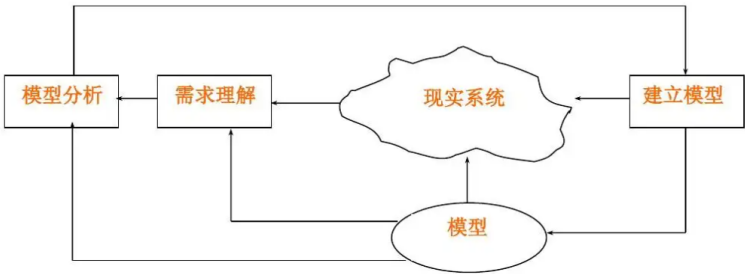


图 1.4 信息系统模型

## （2）神经网络

基于神经网络的故障诊断方法能够通过大量的各种情况下的数据进行学习，存储大量输入输出模型的映射，而不需要先验的数学公式来描述映射关系。该方法会在第 2 章中详细介绍，此处不再赘述。

## （3）支持向量机

支持向量机（support vector machine, SVM）是在 1964 年被提出的，在二十世纪 90 年代后快速发展。SVM 使用铰链损失函数计算经验风险并在求解系统中加入了正则化项以优化结构风险，是一个具有稀疏性和稳健性的分类器<sup>[12]</sup>。SVM 可以在数据集较小的条件下得到较好的学习结果，具有良好的数据泛化能力，其概念如图 1.5 所示。支持向量机算法在模式识别、故障诊断和预测中已经大量运用，发展前景十分广泛，例如在文献[13]中采用 SVM 实现了对滚动轴承多种故障状态的精准辨识。




图 1.5 线性可分向量机

## （4）多元统计分析

基于多元统计分析的故障诊断方法是利用系统运行中各个变量之间的关系进行故障诊断，即根据过程变量数据，采用多元投影方法将多元样本空间分解为两个子空间并在其中构造出变量，然后将检测的向量分别投射至两个子空间中计算变量指标，以便对对象进行监控。文献[14]中提出并展示了一种基于多种多元统计分析技术组合的故障隔离算法效率，成功地检测了电气系统故障并进行分类。

## （5）小波变换

小波变换方法在信号分解、信号降噪和分析中体现出了很好的效果。不同于

---

快速傅里叶变换仅仅能分析数据的频域特征,小波变换通过调整长度和平移对信号进行多尺度的细致分析,能够将非平稳的信号分解为时频域,已被大量运用于各类学科研究领域<sup>[15]</sup>。小波变换能够对于提取的数据进行独立成分分析得到系统特征,通过比对特征以及预先设定的预置来进行故障诊断的工作,例如文献[16]中采用基于 db10 小波数据包的方法识别出输电线路补偿器的故障部分。

### 1.3 基于深度学习的故障诊断研究现状

当今系统的复杂程度不断增加,其组成结构和原理愈发的难以描述,系统的精确模型难以建立。专家知识和经验累积不足,现存的许多故障诊断与预测方法无法适用,而系统运行数据的大量累积和机器学习算法的飞速发展使得基于数据的故障诊断与预测逐渐成为一个充满创新且发展前景广阔的领域<sup>[17]</sup>。

近年来,深度学习在学术界和工业界发展迅猛,在很多传统的识别任务上显著地提高了识别准确率,展示了其高超的解决复合识别问题的能力,吸引了大批专家学者对其理论与应用展开研究<sup>[18]</sup>。目前,故障诊断中使用的深度学习方法主要包括以下四种:基于自动编码器(autoencoder, AE)、深度置信网络(deep belief network, DBN)、卷积神经网络(convolutional neural network, CNN)和循环神经网络(recurrent neural networks, RNN),本节将简单介绍这四种深度学习模型在故障诊断领域中的应用。

AE 是一种无监督学习模型,它不需要对数据标记也能进行特征提取。输入自动编码器的数据通过其内部的编码器压缩到隐藏层中,再通过解码器将其特征进行重组后进入到输出层,其输出和输入是一致的。自编码器在用于异常检测时可以重建对象,有异常输入时会观测到更高的重组误差,这被用作识别异常的标准<sup>[19]</sup>。基于 AE 的故障检测与诊断方法具有以下优势:1)基于 AE 的方法不需要数据标注即可对数据进行特征提取,提高了故障诊断效率;2)基于 AE 的方法泛化性强,网络结构简单,可通过逐层的训练来提炼高阶的非线性特征,具有强大的特征提取能力。目前基于 AE 的方法用在故障诊断的研究已涵盖航空发动机<sup>[20]</sup>、核电站<sup>[21]</sup>、轴承<sup>[22]</sup>、机器人<sup>[23]</sup>等相关领域,并获得了良好效果。

DBN 是一种经典的深度学习模型,它是根据人类大脑的神经网络连接结构构建出来的模型。DBN 由多层受限制玻尔兹曼机(restricted boltzmann machine,

---

RBM)堆叠而成<sup>[24]</sup>，层与层之间有连接，层内无连接。DBN 能够在样本数量有限的情况下学习到数据集的本质特征，达到实现从低级到高级的数据特征提取的目的，特征提取的效果在故障诊断中是十分重要的部分，决定着故障诊断的精度。而 DBN 可以十分有效地避免人工特征提取与选择，降低特征的复杂性和不确定性，增强故障识别的智能性<sup>[25]</sup>。目前 DBN 在故障诊断领域的使用主要有两种类型，一种是用于故障分类<sup>[26]</sup>，另一种是用于特征提取和识别<sup>[27]</sup>。

CNN 是一种被大量用于处理图片数据的神经网络，它是目前使用最广泛的深度学习框架。在 CNN 的一个卷积层中，若干个卷积核的通常为小数矩阵，矩阵中的值为随机小数。通过对网络的训练，卷积核将逐渐得到合适的权值。通过对输入值不断地卷积和池化，CNN 能够提取得到输入值的特征表达。卷积核带来的好处是减少层与层之间的参数数目，有效地避免了过拟合的情况。池化通常有平均池化和最大值池化两种形式，池化层能够减小数据维度，降低模型的体积，优化神经网络的结构。随着科技的发展，海量的工业故障数据需要进行处理训练，而 CNN 非常适合处理海量数据，提取大量数据中的特征，并逐层组合抽象生成高层特征，可有效实现故障诊断与识别<sup>[28]</sup>。

RNN 是一种用于处理序列数据的神经网络，它被广泛的应用于语音识别、视频识别和文本预测等领域。RNN 通过卷积核的参数共享，再按照时间步展开，实现了对时间序列的信息提取，十分擅长于处理和预测时间序列数据。基于 RNN 的故障检测与诊断方法具有以下优势：1) RNN 能够充分挖掘工业生产过程中时间序列数据的动态特征和语义信息；2) RNN 可以处理任意长度的输入输出，且能够在输入数据的维度变化时保持稳定；3) RNN 模型只需输入原始振动信号的时域数据即可成功识别故障模式<sup>[29]</sup>。

故障诊断在处理故障后往往需要给出预防对策，也就是对故障进行预测。故障预测就是通过大量储存的系统状态数据，对系统将来时刻的状态进行预测，以便延长设备的使用寿命。即通过对被预测系统或设备未来的发展趋势建立预测模型，对设备未来的状态进行一定时间内的变化预测，来实现准确、快速地获得设备未来健康情况的目的，包括确定设备和系统的剩余寿命或者剩余寿命的概率分布。文献[30]提出了一种基于多个 DBN 的故障预测模型对设备剩余使用寿命进行预测。文献[31]采用基于 CNN 的方法解决了设备状态检测数据长度不同的问

---

题并实现了精确的预测。文献[32]提出了基于 AE 的方法来预测描述轴承的健康状态。文献[33]利用基于 RNN 的深度学习模型来预测软件中的故障数量并评估软件的可靠性，同时验证了模型的有效性。

## 1.4 论文研究内容和整体结构

本文针对工业生产中的故障诊断问题，研究了故障诊断分类和故障预测难点，提出了多种基于深度学习的诊断和预测方法，同时验证了模型的有效性。

第一章主要介绍了故障诊断在实际生产中的意义、各种传统与新兴的故障诊断方法和基于深度学习的故障诊断方法发展现状。

第二章针对故障诊断分类问题，提出将卷积神经网络用于故障的特征提取和分类工具。分别基于一维、AlexNet 和 GoogleNet 卷积神经网络的思想，构建了三种卷积神经网络模型，对轴承故障数据进行诊断分类测试，结果有效地提取了故障的特征，验证了三种模型在故障诊断方面的效果，同时讨论并对比了各个模型的故障分类能力。

第三章针对提高故障诊断分类准确率的问题，提出将传统信号分析方法中的小波包分解法结合深度学习对故障进行分类。分别基于 AlexNet 和 GoogleNet 卷积神经网络构建两个卷积神经网络模型后，将小波包分解作为数据的预处理手段，将提取后的数据特征放入模型中训练，将分类结果与使用原始故障数据训练的结果进行对比。该方法有效地提高了故障分类精度，验证了小波包分解与深度学习结合能增强对数据的特征提取能力。

第四章针对传统故障信号预测方法的不确定性问题，考虑了故障时序信号的特点，提出构建 LSTM 神经网络模型并用于故障预测。同时针对提高故障预测准确率的问题，提出了 CNN 结合 LSTM 的方法，先采用一维卷积神经网络对故障信号局部特征提取，再用 LSTM 网络对特征进行故障预测。结果验证了两种方法均有良好的预测效果，同时通过对比验证了 CNN 结合 LSTM 能有效地提高故障预测精度。

第五章总结了本文的主要研究工作，并对研究内容下一阶段的工作进行了展望。



## 第 2 章 基于深度学习的故障诊断技术研究

本章首先对神经网络的原理和发展进行了介绍，阐述了多个卷积神经网络的特点；其次针对故障诊断分类问题，分别构建了三种卷积神经网络模型；然后用轴承故障数据对模型进行诊断分类测试，结果有效地提取了故障的特征，验证了模型在故障诊断方面的效果；最后对比并讨论了各个模型的故障分类能力。

### 2.1 卷积神经网络概述

人工神经网络是一种模仿动物神经网络行为特征的复杂网络系统，能够对各个节点进行参数调整，使得系统能够处理各种各样的数据，具有记忆和学习功能。人工神经网络由多个人工神经元构成，人工神经元模型最早在 1943 年被提出，其框架如图 2.1 所示。




图 2.1 人工神经元

其中， $x_i$  表示第  $i$  ( $i=1, 2, 3, \dots, n$ ) 个输入值， $w_i$  表示第  $i$  ( $i=1, 2, 3, \dots, n$ ) 个输入的连接权值， $b$  为该神经元的偏置， $f()$  是对该神经元的一个激活函数， $Y$  是神经元的输出值。多个人工神经元相连形成层，多个神经元层也可以通过将上一层的输出作为下一层的输入的方式进行相连，通常具有多个隐藏层的神经网络就是深度学习网络。人工神经元模型将生物神经元模型转换成逻辑功能器件的模式，结合了生物和数学的特征，为之后的神经网络研究打下了基础。

在人工神经元模型出现前，早期对于数据的分析主要依赖于数学模型的构建，这种方法在实际生活中往往具有一定的局限性。比如对于一个传统的分类模型，在开始分类前往往要提前准备需要的数据特征，然后将对象的特征输入到模型中，但这些特征的设计需要专家来实施。而基于人工神经网络的深度学习方

则省略掉了专家设计特征的这个环节,通过将网络输出和我们期望的输出进行比较,计算出的误差会传播到之前的网络层中,让权重随之而调整。深度学习的特点是不再需要人工提取数据的特征,而是让网络主动地去学习数据的特征,其增强了处理数据的效率和效果,大大提高了图像识别,自然语言处理和其他应用的准确性<sup>[34]</sup>。

卷积神经网络是一种模仿人类视觉皮层,包含卷积计算且的深度前馈神经网络,是常用的深度学习算法之一。卷积神经网络正处于快速发展阶段,已被广泛运用于视觉识别<sup>[35]</sup>、语音识别<sup>[36]</sup>、故障诊断<sup>[37]</sup>等领域。卷积神经网络主要包含输入层,隐藏层和输出层,隐藏层则是由多个卷积层、池化层和全连接层组成,典型的卷积神经网络如图 2.2 所示。




图 2.2 典型卷积神经网络模型

卷积层是 CNN 的关键部分,每个卷积层有若干个卷积核,作用是对于输入的数据仅进行部分区间的运算,进而提取出更细致有效的特征。卷积核在输入数据上移动并进行卷积计算,每次计算不需要对整个数据进行运算,仅针对部分输入数据,降低了运算的成本和复杂度。在卷积层之后紧跟着的池化层能够通过将特征分为几个区域进行运算得到新的低维特征,在不影响每个区域主要特征的基础上,提升模型的泛化能力,减少数据维度,优化网络结构,且能保证在一定程度上位移不变性<sup>[38]</sup>。通常数据在经过多个卷积层和池化层的特征提取之后,会被投入到网络结构最后的全连接层中,此时全连接层把所局部特征结合成全局特征,来对数据进行分类,得到网络最终的输出。

### (1) 激活函数

在许多现实问题中，输入与输出往往不是线性关系，神经网络在处理这类非线性关系问题时需要在网络中加入非线性因素，也就是激活函数。神经网络中常用的激活函数主要包括 Sigmoid 函数、Tanh 函数和 ReLu 函数，由于本文中主要使用的是 ReLu 函数，因此仅对 ReLu 函数作详细介绍。

ReLu 函数是目前深度学习中十分常用的激活函数，当输入为负时，函数输出为 0，输入为正时输出则是输入提供的值，因此 ReLu 函数是一个分段线性函数，ReLu 函数的曲线如图 2.3 所示。




图 2.3 ReLu 激活函数

数学公式为：

$$f(x) = \text{relu}(x) = \max(0, x)$$

ReLu 激活函数的优点为：1) 输入为正时，不会出现梯度饱和的问题；2) 解决了梯度消失的问题；3) 计算量较其他激活函数降低加快了训练速度。其缺点为：1) 当输入为负时，ReLu 无法激活，在反向传播过程中梯度为 0；2) ReLu 函数的输出只有 0 和正数，不以 0 作为输出的中轴。

### (2) 损失函数

在用深度学习处理问题时，需要对搭建好的神经网络框架进行训练，那么在对当前模型的预测准确度进行评判时，我们就需要损失函数作为衡量指标。预测值越接近于真实值，损失值就越小，反之越大。常用的损失函数有绝对值损失函数、均方误差损失函数和交叉熵损失函数。

### (3) 梯度下降

在通过损失函数进行测试后，我们需要调整参数来优化模型，使得训练的结果和实际值更接近，此时常用的优化算法是梯度下降算法。梯度下降法根据更新

---

训练样本数据的规模呈现三种不同的方式：批量梯度下降法、随机梯度下降法和小批量随机梯度下降法<sup>[39]</sup>。梯度下降算法是将网络的权重和偏置值作为自变量，通过改变自变量寻找全局最小点，将误差值降到尽可能的小。因此梯度下降算法的具体做法类似于下山，即计算当前函数的梯度，也就是某一点在空间中上升的最快方向的向量，当梯度大于 0 时，我们需要依据这个方向进行反向移动，使得误差减小。当梯度小于 0 时，我们需要继续沿着这个向量移动。此时变化的值就是神经网络训练的学习率，我们需要选择合适的学习率来保证正确的下山方向，因此通常情况下刚开始模型训练学习率会设置的偏大，之后再减小学习率，使得训练的方向不断接近于下山的最低点。

梯度下降算法的公式为：

$$w = w - \alpha \times \frac{\partial L(w, b)}{\partial w}$$
$$b = b - \alpha \times \frac{\partial L(w, b)}{\partial b}$$

其中， $w$  和  $b$  分别为网络的权重的偏置值， $\alpha$  为学习率， $L(w, b)$  为损失函数，通过输入数据计算而得。

#### (4) 反向传播

神经网络的训练过程包括前向传播和反向传播，其中前向传播指的是由输入在经过网络后得到输出和误差的过程，而反向传播则是通过误差值调整神经网络，也就是梯度下降法在深度网络上的具体应用方式，是一种求梯度的方法。反向传播的主要的思想是计算网络最后输出结果的误差，并且将误差向前反向传递，其能有效地计算出损失函数的偏导数，加快调整网络参数的速度，提高模型训练效率。

## 2.2 基于一维卷积神经网络的故障诊断方法

### 2.2.1 一维卷积神经网络

最初设计卷积神经网络的目的是解决二维图像的识别问题，但大多数工业故障数据是一维时序数据，因此许多研究都是将一维数据通过一些传统数学处理方

法转换为二维图片。但这种方法在某些时候存在局限性，比如丢失了数据特征或者是训练的参数过多，导致计算缓慢影响工业生产的效率。因此有许多研究提出了将二维卷积的思想移植在一维卷积上，搭建出合适的一维卷积神经网络，其主要优点是：（1）具有紧凑的结构配置，仅执行 1D 卷积使其适用于实时故障检测和监控；（2）具有无需任何数据转换即可工作的能力；（3）能够以有限的训练数据集大小和迭代次数为分类任务提供高效的训练<sup>[40]</sup>。许多文献中将经典的卷积神经网络更改为一维卷积神经网络，并对故障数据进行处理，验证了其有效性。例如文献[41]中将振动频率数据作为卷积神经网络的直接输入，训练结果表明一维卷积神经网络能够从一维频率数据中学习特征，并且通过对比其他的方法得到了更高的诊断精度。文献[42]中提出用一维卷积神经网络对人脑头皮的脑电图信号数据进行处理，来检测癫痫的发作。

一维卷积通常是对于序列数据使用，比如振动信号、时域信号等。一维和二维卷积神经网络差别在于：（1）一维卷积神经网络只对长度卷积，对高度不卷积；（2）两者的卷积核滑动方式不同，一维卷积神经网络中的多个卷积核只在一个方向上进行移动卷积计算。如图 2.4 所示，这里以一个卷积核为例，卷积核为 $[-1, 0, 1]$ ，在输入的序列数据上从左向右移动，此时移动的步长为 1，根据卷积核的大小每次框选 3 个数据，分别进行相乘求合计算得到同样是一维数据的结果。通常情况下，输入向量长度远大于卷积核的长度。




图 2.4 一维卷积计算过程

由卷积的计算方式可知，卷积结果的第一个值的结果为：

$$1 \times \textcolor{red}{1} + 1 \times \textcolor{green}{0} + 2 \times \textcolor{blue}{(-1)} = -1.$$

一维卷积层的输出会进入一维池化层，一般的池化计算分为最大池化和均值池化。以图 2.5 为例，池化层输入值是一个向量，采用最大池化计算方式，池化

层的窗口大小为 3，步长为 1，即窗口每次向右移动 1 个步长。第一个窗口中的值为 (5, 3, 4)，最大值为 5，第二个窗口为 (3, 4, 5)，最大值为 5，得到输出值为 (5, 5)。




图 2.5 一维池化窗口移动过程

## 2.2.2 基于一维卷积神经网络的故障分类能力分析

### (1) 实验数据集介绍

本文选用的数据均基于美国西储大学的轴承数据集，实验平台如图 2.6 所示。




图 2.6 美国西储大学轴承故障实验平台

实验平台由一个 2 马力的电动机，一个扭矩传感器，一个功率测试计和一个电子控制器组成。设备中各安装了一个加速度传感器在轴承驱动端和风扇端，用于收集数据信号，采样频率为 12kHz，电机转速范围均在 1730-1797rpm 范围内。实验是通过人为制造电火花产生电机轴承的故障，并记录下电机的测试条件与轴承的故障状态。轴承故障的位置分为轴承内圈故障、外圈故障和滚珠故障，外圈故障中又分为 3 点钟、6 点钟、12 点钟故障位置。同时每个故障根据 0.007, 0.014, 0.021, 0.028 英寸四个故障的尺寸分为若干个，并且每一类故障数据都会在四种不同的负载情况下分别收集，分别为无负载，1、2、3 马赫负载。采样频率为 12KHz 的数据集中包含的数据类别如表 2.1 所示。

设备状态	负载情况(马赫)	故障尺寸(英寸)
正常	0、1、2、3	\
内圈故障	0、1、2、3	0.007, 0.014, 0.021, 0.028
外圈故障(@6:00)	0、1、2、3	0.007, 0.014, 0.021
外圈故障(@3:00)	0、1、2、3	0.007, 0.021
外圈故障(@12:00)	0、1、2、3	0.007, 0.021
滚珠故障	0、1、2、3	0.007, 0.014, 0.021, 0.028

表 2.1 数据集各状态分类

## (2) 实验数据选取和数据处理

本实验中选取了数据库中的十种轴承状态，均是负载为 3 的情况，包括一种正常状态数据和九种驱动端故障数据。这九种故障数据的故障位置分别为轴承内圈故障、外圈故障（@6:00）和滚珠故障，每种分类中又根据故障大小的直径选取了 0.007 英寸、0.014 英寸和 0.021 英寸三个等级。

数据处理通过窗口采样的方式，在每一个类别中以 2048 个采样点作为窗口大小，窗口以 1000 个采样点作为步长移动 119 次，根据公式共需要 121048 个采样点，得到 120 个数据样本，十个类别总共得到 1200 个数据样本。将每个样本进行归一化处理，并随机打乱 1200 个样本，根据 3: 1 的比例，将 900 个样本作为训练集，300 个样本用来测试模型的结果。

## (3) 实验环境设置

本实验使用常用的 Google 开源 tensorflow 框架，并选用 GPU 版本提高训练速度，实验开发环境为 python3.6 版本，开发工具为 Pycharm，计算机操作系统为 win10 版本，GPU 型号为 1060Max-Q，GPU 内存大小为 6G。

## (4) 一维卷积神经网络模型设计和测试结果

本实验设计的一维神经网络结构包括三个卷积大层和一个全连接层，每个卷积大层包括一个卷积层和一个最大池化层，每个卷积层和最大池化层之间都加入了 ReLu 激活函数。网络的输入数据长度为 2048，网络结构如图 2.7 所示。




图 2.7 一维卷积神经网络结构

具体来说，模型各网络层的参数如表 2.2 所示。

网络层	参数	网络层	参数
conv1d	$7 \times 8$	max_pool	2
conv1d_1	$3 \times 16$	max_pool_1	2
conv1d_2	$3 \times 32$	max_pool_2	2
dense	10		

表 2.2 各网络层参数

网络各卷积层的卷积核长度分别为 7、3、3，数量分别为 8、16、32，最大池化层均选用长度为 2 的滤波器，dense 参数为 10 表示最后全连接层的输出维度为 10，表示 10 种状态分类。设置学习率为 0.001，对模型的训练如下图 2.8 所示。其中，图中绿线代表训练损失值，红线代表训练准确率。






图 2.8 一维卷积神经网络训练过程

由图可知模型的分类准确率均匀上升,在接近 270 次迭代时出现了损失值突然上升又逐渐下降的情况,考虑是在参数更新的过程中某一个值的突变影响了整个模型的准确率。因此在整体参数没有大变化的情况下,模型的损失快速下降并恢复到原先的下降趋势,此情况基本属于正常现象。在 400 次迭代后,模型的准确率变化趋于平稳,损失值仍在缓慢下降,因此还有学习空间,800 次迭代之后再对模型进行多次微调训练,在测试集上进行验证,最后一次训练结果和测试结果如表 2.3 所示。

训练结果		测试结果	
准确率	损失值	准确率	损失值
0.997778	0.030128	0.933333	0.306344

表 2.3 训练和测试结果对比

由表可知模型在训练中的准确率已经接近于 100%,但在测试集上的准确率仅 93.3%,两者差值较大,模型出现了一定程度的过拟合情况,测试准确率尚且没有达到预期值,可能由于一维卷积神经网络的特征提取能力不足。这启发我们在接下来的章节中考虑采用二维卷积神经网络,进而提高故障分类的准确率。

## 2.3 基于 AlexNet 卷积神经网络的故障诊断方法

### 2.3.1 AlexNet 卷积神经网络

本节实验采用的是常用于图像处理的二维卷积神经网络进行故障分类，尝试提高故障分类的准确率。以图 2.9 为例，对二维卷积的计算方式进行介绍，输入数据是一个  $5 \times 5$  大小的二维数据，卷积核是一个  $3 \times 3$  大小的滤波器，卷积核在输入数据上由左向右，由上往下不断移动计算，依次得到输出矩阵中的值。




图 2.9 二维卷积计算方式

此时卷积核从左向右移动两次后到达数据的右上角，根据卷积计算公式，卷积核与输入数据中对应的  $3 \times 3$  矩阵进行运算，运算结果为输出数据的右上角值，计算式为：

$$-1 \times 1 + 0 \times 1 + 0 \times 1 + 0 \times (-3) + 0 \times 0 + 0 \times 1 + 0 \times 1 + 0 \times (-1) + 1 \times 0 = -1$$

二维池化也与一维池化有所不同，如图 2.10 所示。



图 2.10 二维最大池化方式

图中池化层输入数据格式为  $4 \times 4$ ，滤波器大小为  $2 \times 2$ ，步长为 2，采用最

---

大池化的方式，对左上角的  $2 \times 2$  区域取最大值 4，滤波器再向右移动 2 个单位，取最大值 6，依次得到池化层的输出。对于复杂的输入数据，用卷积操作进行提取的特征肯定不止一种，为了提取更加复杂的数据特征，我们需要使用多个具有不同功能的卷积核来进行卷积计算。比如当输入数据是多通道的 RGB 彩色图时，需要处理 3 个通道，当卷积层有 2 个卷积核时，我们就能通过卷积操作得到 2 个特征图。

### （1）AlexNet 模型概述

AlexNet 卷积神经网络结构是在 2012 年由多伦多大学的学生 Alex Krizhevsky 设计的，并在当年夺得了 ImageNet LSVRC 的冠军。同时该模型的错误率为 15.3%，以极大的优势超过了第二名的 26% 错误率。AlexNet 模型具有重要的历史意义，也是在那年之后，许多优秀的深度神经网络结构被相继提出，比如 GoogleNet 等，同时 AlexNet 也是研究最多的卷积神经网络<sup>[43]</sup>。

AlexNet 模型的创新之处主要有以下几点：1) 成功地使用了 ReLu 替代传统的 Sigmoid 作为激活函数，同时验证了 ReLu 在更深的神经网络结构中能表现的更加出色，解决了 Sigmoid 收敛较慢的问题；2) 采用了数据增强技术，对有限的训练数据集进行翻转、平移和裁剪等，产生了更多的训练数据，减少了过拟合，提高了模型泛化能力；3) 使用了层叠的最大池化方法，在此之前大多数 CNN 都采用了平均池化，比如早期的 LeNet 模型，此时滤波器的步长和滤波器的窗口长度相同，也就是说池化的过程中不会出现数据的重叠。而 AlexNet 只使用最大池化方式，同时步长比滤波器窗口长度小，这样池化层处理的数据会有重叠的部分，可以提高特征的多样性，有效地避免过拟合。4) 为了减少模型过拟合程度，在全连接层加入 dropout 技术，随机将一部分神经元置为 0，同时保持神经元的数量不变，对参数进行正常更新。更新后再随机将神经元置 0，不断地重复此过程。5) 采用局部响应归一化提高模型泛化，对局部的神经元进行比较，将其中响应明显的值进行增强放大，并抑制其他响应较弱的神经元，这能有效地降低模型的错误率。

### （2）AlexNet 模型结构

AlexNet 的具体结构由图 2.11 所示，由于设计者使用了两个 GPU 进行并行计算，因此网络分为了上下两层，但计算过程是完全相同的。AlexNet 的结构为 8

层，包括 5 个卷积层和 3 个全连接层，网络总共具有 6000 万个参数和 65 万个神经元。前两个卷积层的操作依次为卷积-激活函数-池化-局部响应归一化，之后卷积层依次为卷积和激活函数操作，只是最后一个卷积层多了一个池化的操作。前两个全连接层都加入了激活函数和 dropout 来抑制过拟合，最后一个全连接层的输出为 1000 维的预测结果。




图 2.11 AlexNet 模型结构

以第一个卷积层 Conv1 为例进行简要介绍，该层的输入的数据大小为  $224 \times 224$ ，通道数为 3。总共有 96 个卷积核，平均分配在两个 GPU 上，卷积核的大小为  $11 \times 11$ ，通道数也为 3。卷积核步长 stride 为 4，padding 设为 [1, 2] 表示在卷积的过程中将矩阵的左侧补一行 0，右侧补 2 列 0，上侧补一行 0，下侧补 2 行 0，因而卷积核能够超出原矩阵的边框进行计算。

卷积层对其下一层的输出为  $N \times N$ ，计算公式为  $N = (W - F + 2 \times p) / s + 1$ ，其中输入图片大小为  $W \times W$ ，卷积核大小为  $F \times F$ ， $2p$  为 padding 的总像素， $s$  为卷积核的步长。代入数据可知 Conv1 的输出大小为  $(224 - 11 + 3) / 4 + 1 = 55$ ，通道数为 96，因此下一层的输入数据为  $55 \times 55 \times 96$ 。

## 2.3.2 基于 AlexNet 卷积神经网络的故障分类能力分析

### (1) 实验数据选取和数据处理

本节实验继续使用上一节的轴承故障数据集进行故障分类能力分析，但数据的大小有所调整。由于本节使用的是二维卷积神经网络，因此将原大小为 2048 的一维数据转换为  $32 \times 64$  的二维数据，将 900 个样本作为训练集，300 个样本作为测试集。

## (2) 基于 AlexNet 卷积神经网络模型设计和测试结果

本节的网络基于 AlexNet 模型的思想，构建了一个具有三层卷积层、三层池化层和一个全连接层的卷积神经网络，每个卷积层和池化层之间都加入了 ReLu 激活函数，提高了模型的非线性功能，且比 sigmoid 计算速度更快。全连接层之前加入了 dropout 层抑制过拟合，全连接层输出为 10 维数据，即对故障进行十分类，具体的网络结构与各个层的参数如图 2.12 所示。




图 2.12 基于 AlexNet 的卷积神经网络结构

分别以第一个卷积层和第一个池化层为例，输入数据的格式为  $32 \times 64 \times 1$ ，卷积核的数量为 16 个，大小为  $5 \times 5$ ，步长为 1，padding 设置为 SAME，即在卷积的过程中自动补全矩阵周围的 0，因此得到的输出格式为  $32 \times 64 \times 16$ 。卷积层的输出数据作为卷积层的输入数据，池化层采用最大池化计算，滤波器的大小设置为 2，步长设置为 2，因此得到池化层的输出格式为  $16 \times 32 \times 16$ 。为了减少神经网络过拟合，提高网络模型在测试集上的准确率，本实验在全连接层还加入了 dropout 层。Dropout 能够在每一次的训练中随机删减一些神经元，删掉的比例可以由使用者设定，这时在训练中只会更新没有删掉的神经元的参数，然后再开始下一次的训练，这样能够减少中间特征的数量，提高模型的泛化能力，本实验设置了 0.5 的 dropout 比例，也就是每次训练随机舍弃掉 50% 的神经元。

设置 0.003 的学习率，对模型进行 700 次迭代训练，结果如图 2.13 所示。其中，绿线代表模型准确率，红线代表模型损失值。




图 2.13 基于 AlexNet 的卷积神经网络训练过程

由图可知训练初期模型的损失下降非常快，准确率的上升也较快，直到 600 次迭代后准确率上升开始趋于平缓，尽管损失值和准确率均出现了小幅度振荡，但考虑是参数更新的正常情况。但在之后对模型微调的 300 次迭代过程中，发现准确率的振荡较为严重，且整体几乎不再上升，如图 2.14 所示。




图 2.14 基于 AlexNet 的卷积神经网络训练过程

考虑准确率振荡的原因是学习率设置过大，导致模型在参数更新时无法找到最优解，将学习率修改为 0.001 后继续训练，训练过程如图 2.15 所示。




图 2.15 基于 AlexNet 的卷积神经网络训练过程

在修改学习率后的初始阶段模型准确率骤升，损失值也骤降，之后准确率和损失值缓慢变化，说明模型仍有学习的空间，再对模型进行多次微调训练，在测试集上进行验证，最后一次训练结果和测试结果如表 2.4 所示。

训练结果		测试结果	
准确率	损失值	准确率	损失值
0.993333	0.110516	0.953333	0.210220

表 2.4 训练和测试结果对比

本次实验模型学习效果优秀，分类准确率相较于一维卷积神经网络得到了提升，可以看出 AlexNet 的特征提取能力更强，且模型训练准确率和测试准确率更为接近，判断是加入 dropout 层后起到的抑制过拟合效果能让模型泛化能力增强，测试时能达到更高的精度。为了让故障分类准确率进一步提高，我们在下一章节中尝试基于另一种经典的卷积神经网络（GoogleNet）思想，设计出故障分类效果更好的模型。

## 2.4 基于 GoogleNet 卷积神经网络的故障诊断方法

### 2.4.1 GoogleNet 卷积神经网络

#### (1) GoogleNet 模型概述

GoogleNet 模型在 2014 年被 Christian Szegedy 提出，同时也是当年的 ImageNet 比赛中分类任务的第一名。GoogleNet 的特点是其网络层数达到了 22 层，但参数的数量却不到 AlexNet 的十分之一。在 GoogleNet 之前的网络模型大多是通过增加网络的层数来提高模型的精度，然而过多的层数会带来过多的参数数量，容易在训练数据不足的情况下导致过拟合，同时也容易出现梯度消失，梯度爆炸等现象。针对这些情况，GoogleNet 的核心思想是采用稀疏连接代替全连接，同时不浪费有限的计算资源，因此提出了 inception 模块结构。Inception 模块能够高效的利用计算资源，提取到相同数量特征的同时只需要较少的计算量，因而提升训练结果。GoogleNet 已被大量的研究所使用，文献[44]中提出了一种基于 GoogleNet 的自动驾驶算法来自动控制汽车，文献[45]中使用 GoogleNet 来检测汽车的机械故障。

#### (2) GoogleNet 模型结构

整个 GoogleNet 实际上就是 inception 的重复叠加使用。GoogleNet 的核心部分就是 inception 模块，如图 2.16 所示。

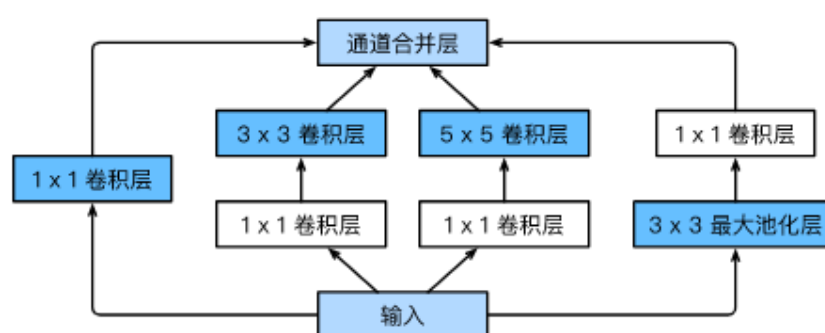


图 2.16 inception 模块结构

Inception 是一个将几个卷积层和池化层组合在一起的模块，里面使用了  $1 \times 1$  的卷积层，目的是能提取到更多样的特征，同时对数据降维，比单独使用  $3 \times 3$  或  $5 \times 5$  大小的卷积层减少了参数数量，降低计算的复杂度，而且也不会对结果



产生负面效果。inception 通过多个卷积或池化操作对图像提取不同尺度的特征，最后再在深度维度进行拼接。这种结构带来了几种好处：（1）能提取到更加丰富的特征，提高数据分类的精度。（2）降低计算量，加快了网络收敛速度。GoogleNet 的网络保留了 dropout 操作，最后还使用了平均池化层代替了全连接层，极大减少了参数的数量，防止网络过拟合，但由于失去了全连接层，学习压力积累在卷积层上，一定程度降低了网络收敛速度。

## 2.4.2 基于 GoogleNet 卷积神经网络的故障分类能力分析

本节实验选取与上一节相同的数据集，数据输入格式为  $32 \times 64$ ，训练集样本数为 900，测试集样本为 300。网络设计基于 GoogleNet 模型的思想，构建了两个卷积与池化相互交替的大层，并引入了一个 inception 模块，用于增加网络的深度和宽度，将平均池化层代替之前的全连接层来降低参数的数量，抑制网络过拟合的程度，网络的具体结构如图 2.17 所示。

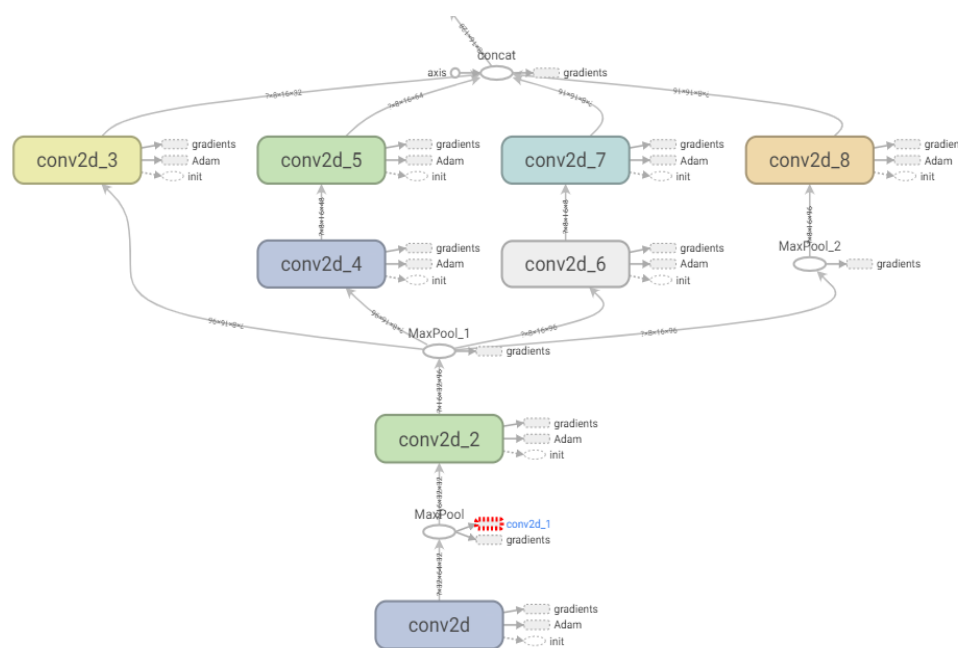


图 2.17 基于 GoogleNet 的卷积神经网络结构

其中第一个卷积层卷积核大小设置为  $7 \times 7$ ，数量为 32 个，第二个卷积层卷积核大小减小为  $3 \times 3$ ，数量为 96 个，前两个最大池化层的滤波器大小为  $2 \times 2$ ，步长为 2，用于减小数据维度。之后再连接 inception 模块，inception 结构为 inception v1 版本，inception 的具体参数如表 2.5 所示。

	Conv2d_3	Conv2d_4	Conv2d_5	Conv2d_6	Conv2d_7	Conv2d_8
卷积核数目	32	48	64	8	16	16

表 2.5 inception 参数

对模型进行训练，设置学习率为 0.002，模型迭代 500 次的过程如图 2.18 所示。其中，绿线代表模型准确率，红线代表模型损失值。




图 2.18 基于 GoogleNet 的卷积神经网络训练过程

由图可知模型的准确率整体处于上升，但是在迭代中损失值多次出现了极大的偏差，且并没有快速的修正，而是不断地迭代后才回到原先的变化趋势，考虑是学习率过大导致出现了类似梯度爆炸的现象，因此将学习率由 0.02 调整为更小的 0.002，再对模型进行训练，训练过程如图 2.19 所示。




图 2.19 基于 GoogleNet 的卷积神经网络训练过程

由图可知在调整模型学习率后，损失值和准确率均开始稳定变化，不再出现突变的情况，之后再对模型进行多次微调训练，将训练过后的模型在测试集上验证，最后一次训练结果和测试结果如表 2.6 所示。

训练结果		测试结果	
准确率	损失值	准确率	损失值
0.996667	0.025820	0.980000	0.053405

表 2.6 训练和测试结果对比

本次实验模型的测试准确率较上节实验有显著的提升，能准确地对数据进行识别和分类，且模型的收敛速度也略有提升。同时模型在训练集和测试集上的准确率仅相差约 2%，模型的泛化能力优异，基于 GoogleNet 的模型对于特征的提取更优秀，能很好地完成故障十分类任务。

为了提高故障分类的准确率，我们研究 inception 模块在 GoogleNet 中的重要性以及对于故障分类的作用，在上一个模型的基础上再增加一层 inception 进行对比实验，网络具体结构如图 2.20 所示。

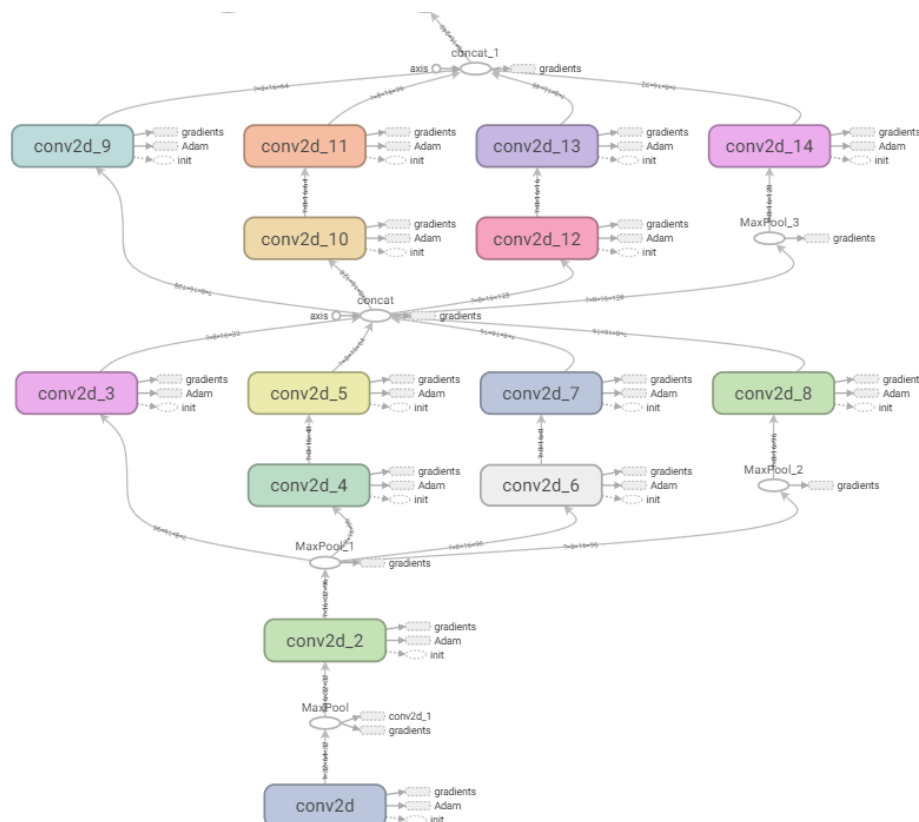


图 2.20 基于 GoogleNet 的卷积神经网络结构(两层 inception)

Inception 层之前的卷积池化层参数保持不变，之后再连接两个 inception 模块，inception 结构均为 inception v1 版本，各 inception 的具体参数如表 2.7 所示。

Inception1	卷积核数目	Inception2	卷积核数目
conv2d_3	32	conv2d_9	64
conv2d_4	48	conv2d_10	64
conv2d_5	64	conv2d_11	96
conv2d_6	8	conv2d_12	16
conv2d_7	16	conv2d_13	48
conv2d_8	16	conv2d_14	32

表 2.7 inception 模块参数

设置模型的学习率为 0.0005，对模型进行 500 次迭代训练，训练过程如图 2.21 所示。其中，绿线代表模型准确率，红线代表模型损失值。




图 2.21 基于 GoogleNet 的卷积神经网络训练过程(两层 inception)

由图可知在 250 次迭代训练后模型的收敛结果优秀，但在训练过程中模型出现了与上一节实验相同的情况，即损失值突然的上升，且由于训练初期模型的准确率上升较快，而模型收敛速度往往与学习率有关，基本推测发生该情况的原因也是因为学习率设置较大。而本节实验设置的学习率仅为 0.0005，因此可得出基于 GoogleNet 的卷积神经网络需要较一般神经网络更小的学习率进行训练。之后再对模型进行多次迭代微调，最后一次训练结果和测试结果如表 2.8 所示。

训练结果		测试结果	
准确率	损失值	准确率	损失值
0.998889	0.024021	0.996667	0.013532

表 2.8 训练和测试结果对比

最终模型的训练准确率接近于 100%，并且模型的测试准确率与训练准确率十分接近，差值约为 0.2%，同时损失值非常低，模型的泛化能力极为优秀，在增加了一层 inception 模块后，网络的宽度和深度都得到了提升，能够在提升宽度和深度的情况下抑制过拟合，因此得到了更高的准确率。但模型在测试集上的损失要低于在训练集上的损失，考虑是由于在训练过程中加入了 dropout 层，作用是随机地将部分神经元暂时删除，因此在提高模型泛化能力和测试精度的同时牺牲了训练集的损失值。本实验体现出了 inception 模块的重要性，故障分类能力较之前得到了极大的提升。

## 2.5 本章小结

本章针对轴承故障诊断问题，分别提出并设计了基于一维卷积神经网络、基于 AlexNet 和基于 GoogleNet 的三种诊断方法，提取三种模型内在的优点构建出三个新的框架并验证了有效性，同时验证了 inception 层数的增加对于故障分类效果的提升。采用滑动窗口采样的方法对数据进行预处理，增大数据集的数量，增强数据特征的提取。对网络训练后在测试集上进行故障分类效果验证，并进行对比，如表 2.9 所示。

一维卷积神经网络		基于 AlexNet 卷积神经网络	
准确率	损失值	准确率	损失值
0.933333	0.306344	0.953333	0.210220
基于 GoogleNet 卷积神经网络 (1 层 inception)		基于 GoogleNet 卷积神经网络 (2 层 inception)	
准确率	损失值	准确率	损失值
0.980000	0.053405	<b>0.996667</b>	<b>0.013532</b>

表 2.9 各模型测试中的准确率和损失值

同时将每个模型在训练集和测试集上的准确率之差进行计算和对比，结果如表 2.10 所示。

一维卷积神经网络	基于 AlexNet 卷积神经网络
0.064445	0.040000
基于 GoogleNet 卷积神经网络 (1 层 inception)	基于 GoogleNet 卷积神经网络 (2 层 inception)
0.016667	<b>0.002222</b>

表 2.10 各模型分别在训练和测试中的准确率之差

综上，通过相同的数据集训练与测试，三种神经网络模型均有不错的分类效果。基于 GoogleNet 卷积神经网络诊断方法比另外两种方法损失更低，故障分类的准确率更高，且测试和训练的准确率更为接近，模型的泛化能力更强。当两个 inception 模块叠加使用时，能够达到接近 99.7%的准确率，300 个样本中仅有 1 个样本分类错误，完全可以满足工业对于故障诊断的需求。

为了提高故障分类的准确率，我们除了对模型框架和参数进行设计修改，还可以通过数据处理的方式提取数据的特征，让模型得到效果更好的训练。因此在下一章节中我们考虑将传统信号分析与深度学习进行结合，进而提高故障分类的准确率。

---

## 第3章 基于小波包分解与卷积神经网络的故障诊断 技术研究

本章介绍了传统的信号分析方法，针对提高故障特征提取能力，提出将信号分析法中的小波包分解法与深度学习相结合。首先将小波包分解作为数据的预处理手段；其次分别构建两种卷积神经网络，将小波包提取后的特征放入模型中训练；最后将故障分类结果分别与使用原始故障数据分类结果进行对比，结果表明该方法提高了故障分类精度，验证了小波包分解与深度学习结合能有效地提取故障特征。

### 3.1 小波包分解概述

为了提高故障分类的准确度，提高故障特征提取能力，除了根据数据修改神经网络结构，还能通过传统的数学方法对数据处理，改变数据的表现形式，提高网络学习的效果。但传统的信号分析方法在面对非平稳的信号时，无法体现出信号的时域和频域局部化等特性。为了解决此问题，很多情况人们选择采用小波变换的方式，对信号进行时频局部化分析，但小波变换只对信号的低频成分进行处理，对信号的高频成分不再做分解，因此在面对含有大量高频部分的信号，如机械振动信号时，采用小波变换会失去很多关键特征，影响分析效果。所以在故障诊断领域，通常选用小波包分解的方式对数据进行处理，其具有多分辨率分析的特点和扎实的理论基础<sup>[46]</sup>。小波包分解会将初始信号分解为低频信号和高频信号，下一次分解时，又将每个部分分为低频和高频，实现信号在不同频率、不同时间的特征分解。由于小波包会对高频信号进行分解，因此小波包分解得到的结果比小波变换的分辨率更高，得到的信号特征更加精细和丰富。当对信号进行三次小波包分解时，分解过程如图 3.1 所示。




图 3.1 三次小波包分解过程

$S_{0,0}$  为需要分析的初始信号，以信号  $S_{1,0}$  为例，1 表示分解的第 1 层，0 表示当前层的第 0 个分解的信号。图 3.1 中经过低通滤波系数  $g(k)$  获得的是信号的低频部分，而经过高通滤波系数  $h(k)$  获得的是信号的高频部分，对每一层的信号进行分解后得到下一层低频信号和高频信号的计算公式分别为：

$$S_{i+1,2j}(n) = \sum_k g(k-2n)S_{i,j}(k),$$

$$S_{i+1,2j+1}(n) = \sum_k h(k-2n)S_{i,j}(k).$$

根据公式我们就能不断地对信号进行分解，得到数据的多个低频和高频特征细节。

## 3.2 基于小波包分解与卷积神经网络的故障分类能力分析

### 3.2.1 基于小波包分解与 AlexNet 的故障分类能力分析

#### (1) 实验数据选取和小波包数据处理

本节实验选取轴承的十种状态数据，即 9 种故障数据和 1 种正常数据，每种状态选取 100 个数据点，得到总共 1000 个数据点。接着通过小波包分解对数据进行预处理，选用 db3 小波包对信号进行小波包分解，针对二维的卷积神经网络，设计使用  $16 \times 16$  的数据进行训练，因此进行 8 次分解得到 256 个子频带，再通过频带能量分析方法，得到 256 个子频带的能量谱，为了提高训练效果，对数据进行归一化，得到 256 个数据特征。最终的数据集大小为  $1000 \times 256$ ，总共有 1000



个样本，每个样本具有 256 个数据点，将样本随机打乱后，前 900 个样本作为网络训练集，后 100 个样本作为测试模型效果的测试集。

同时为了验证小波包分解对于提升故障诊断精度的效果，制作一个相同大小的数据集。仍然选取 9 种故障数据和 1 种正常数据，通过滑动窗口采样的方式，以 256 个采样点作为窗口大小，窗口滑动步长为 100，每滑动一次取一次样本，每种状态取 100 个样本，十种状态共得到 1000 个样本，需要 101560 个采样点。同时将样本随机打乱后，按照 9: 1 的比例，得到 900 个训练集样本和 100 个测试集样本。

### (2) 基于小波包分解与 AlexNet 模型的网络结构设计和测试结果

本节实验基于小波包处理后的数据与 AlexNet 网络模型，构建了一个卷积神经网络。为了匹配二维神经网络，将数据的输入格式由  $256 \times 1$  转换为  $16 \times 16 \times 1$ ，网络的具体结构如图 3.2 所示。




图 3.2 基于 AlexNet 的卷积神经网络结构

相对于第二章，由于数据大小的缩减，为防止参数过多导致过拟合，本次实验设计的网络由两层卷积层，两层最大池化层加上一个全连接层组成，在全连接层之前加入了 dropout 防止过拟合，比例为 50%。第一个卷积层的卷积核大小为  $7 \times 7$ ，深度为 8。第二个卷积核大小为  $3 \times 3$ ，深度为 16。池化层的滤波器大小和步长均为 2，所有的 padding 均设置为 SAME，即在计算过程中自动对输入数据的四周补 0。设置学习率为 0.002，使用同样的网络分别对无小波包分解和小波包分解的数据集进行 2000 次迭代训练，如图 3.3 和图 3.4 所示。




图 3.3 原始数据训练过程




图 3.4 数据经小波包分解后训练过程

由图可知使用小波包分解后的数据进行训练，基于 AlexNet 的模型准确率上升速度更快，模型收敛需要的迭代次数更少，经过 400 次迭代准确率就几乎达到了原始数据迭代 800 次的大小。在 2000 次迭代后模型基本趋于平稳状态，再对模型进行多次迭代微调，最终各自的测试结果如表 3.1 所示。

无小波包分解		有小波包分解	
准确率	损失值	准确率	损失值
0.960000	0.078609	<b>0.970000</b>	<b>0.060288</b>

表 3.1 两种情况下测试的准确率和损失值

两种情况的分类准确率均很高，但在小波包分解处理之后，模型准确率提高了 1%，损失值下降了约 0.02，体现出小波包分解有效地提取了数据特征，提高了故障分类的准确率。同时由于在小波包分解后数据的数量大幅增加，因此在面对现代工业常常出现的故障数据相较正常数据严重不足的情况下，小波包分解能够在为网络增加训练样本数量的同时提高故障分类的精度，符合大规模工业的故障诊断需求。

### 3.2.1 基于小波包分解与 GoogleNet 的故障分类能力分析

本节实验使用的数据集与上一节相同，即使用原始数据和小波包处理后的数据，并将他们分别投入到基于 GoogleNet 模型构建的神经网络中进行训练，对比测试结果，来验证小波包分解对于故障分类问题的作用，本次实验设计的网络结构如图 3.5 所示。

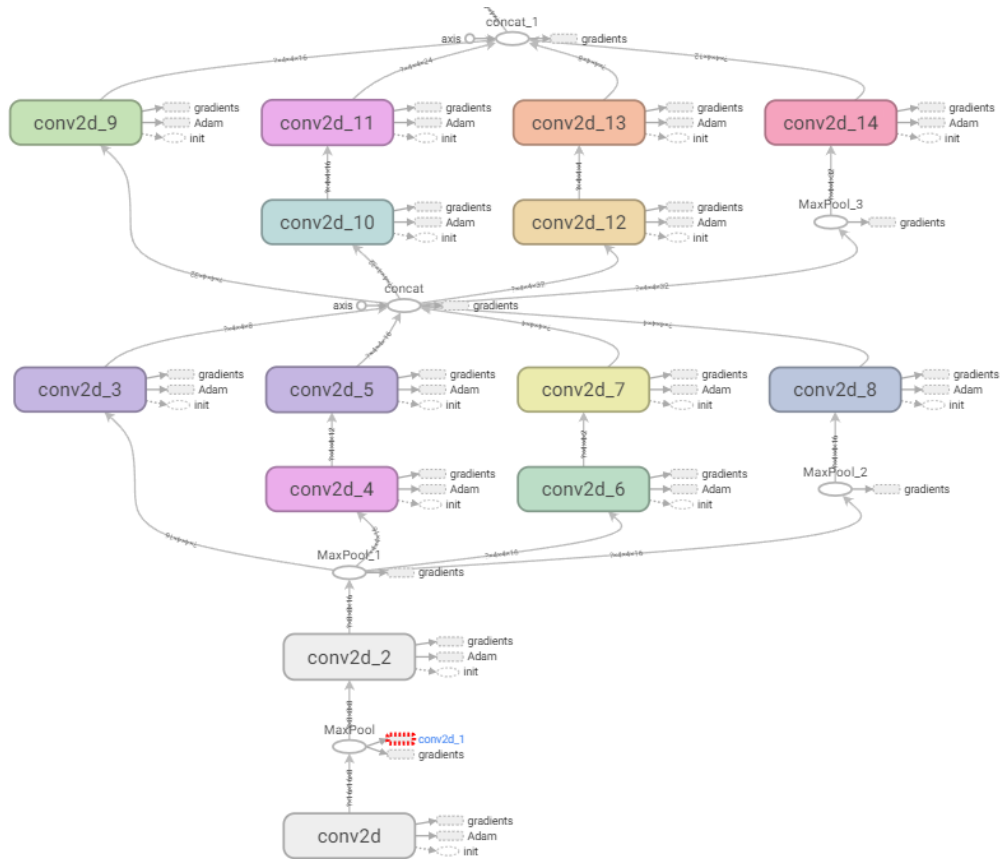


图 3.5 基于 GoogleNet 卷积神经网络结构

相较于上一章，本节实验的数据集格式有所减小，因此各个网络层的参数也需随之减小避免过拟合，参数与上一章中基于 GoogleNet 模型的网络有所不同，

第一个卷积层的卷积核大小为  $7 \times 7$ ，数量为 8，第二个卷积层的卷积核大小为  $3 \times 3$ ，数量为 16，之后连接两个 inception 模块，inception 模块后用平均最大池化层代替全连接层，inception 模块各参数值如表 3.2 所示。

Inception1	卷积核数目	Inception2	卷积核数目
conv2d_3	8	conv2d_9	16
conv2d_4	12	conv2d_10	16
conv2d_5	16	conv2d_11	24
conv2d_6	2	conv2d_12	4
conv2d_7	4	conv2d_13	8
conv2d_8	4	conv2d_14	12

表 3.2 inception 模块参数

设置学习率为 0.0005，使用小波包分解的数据和原始数据对同一个网络进行训练，训练过程分别如图 3.6 和图 3.7 所示，绿线和红线分别代表准确率和损失。




图 3.6 原始数据训练过程




图 3.7 数据经小波包分解后训练过程

由图可知，使用小波包分解后的数据进行训练，基于 GoogleNet 的模型收敛速度下降，但在训练后期使用原始数据的模型准确率变化逐渐变得平缓，而使用小波包分解的模型准确率仍有较明显的上升趋势，模型仍有学习的空间，对两个模型再经过多次迭代微调，最终各自的测试结果如表 3.3 所示。

无小波包分解		有小波包分解	
准确率	损失值	准确率	损失值
0.940000	0.219905	<b>0.970000</b>	<b>0.180954</b>

表 3.3 两种情况下测试的准确率和损失值

由表 3.3 可知，使用小波包分解处理后的数据，模型训练后进行测试的损失值比使用原始数据降低了约 0.03，准确率上升了约 3%，小波包分解处理的效果比上一小节更为显著，经过的小波包分解后的数据特征更容易被卷积神经网络所学习并分类。同时在本实验之后分别对数据进行了 9、10 和 11 层的小波包分解操作，再使用相同的网络进行学习，效果远远达不到有效进行故障分类的程度。因此小波包分解并不是层数越多越好，需要依据实际情况选择适当的层数。

### 3.3 本章小结

本章通过故障特征提取中存在的特征丢失情况，考虑了信号分析方法中的小波包分解法能够保留数据的特征，提取数据的细节，将小波包信号分析作为数据预处理手段与两种卷积神经网络框架相结合，提出两种故障诊断方法，并通过对故障分类问题进行结果验证比较，验证了小波包分解对于故障分类问题的有效性，对比结果如表 3.4 所示。

基于 AlexNet 网络模型				基于 GoogleNet 网络模型			
无小波包分解		有小波包分解		无小波包分解		有小波包分解	
准确率	损失值	准确率	损失值	准确率	损失值	准确率	损失值
0.96	0.078609	<b>0.97</b>	<b>0.060288</b>	0.94	0.219905	<b>0.97</b>	<b>0.180954</b>

表 3.4 四种情况下测试的准确率和损失值

根据表格可知，四种情况故障分类准确度大小排列为：基于 AlexNet（小波包）=基于 GoogleNet（小波包）>基于 AlexNet >基于 GoogleNet，由此小波包分解对于此故障分类任务的效果得到了验证。其中基于 AlexNet 模型（小波包）和基于 GoogleNet 模型（小波包）的测试准确率相同，但前者的损失值更低，也就是预测的值更接近于目标值，因此基于 AlexNet 模型的网络与小波包分解结合的故障分类效果最优秀。

## 第 4 章 基于 LSTM 神经网络的故障预测技术研究

在实际生产中，故障诊断的最后一个环节往往是给出预防对策，对未来的故障进行预测。本章目的在于解决对于轴承时序信号的故障预测问题，提出有效的方案。由于时序信号通常具有复杂的周期性、时间关联性以及复杂的整体逻辑，传统神经网络难以针对时序信号中的信息进行处理。前两章中使用的卷积神经网络对于时序信号的处理也欠佳，由于卷积神经网络没有记忆功能，难以处理先前时刻的数据，而且其卷积的计算过程在预测问题中会导致信号时序特征的丢失，故不适用于故障的预测，而循环神经网络可以在其自身结构内传递网络状态，适用于时序信号的描述。

### 4.1 LSTM 神经网络概述

对于有明显规律的序列化输入，每个时刻的值往往都与之前时刻的值有关联，预测时需要依赖之前的输入，比如对语音的下一刻内容的预测，传统神经网络无法处理序列信息，不会关注之前时刻的数据信息，仅仅能够处理单一时刻的样本数据。为了使网络拥有一定的记忆能力，循环神经网络的结构便应运而生。

循环神经网络是一种特殊的神经网络结构，是神经网络序列模型的主要实现形式<sup>[47]</sup>。其核心思想是通过其指向自身的环，对上一层网络的信息进行保存记忆，并用于当前层的计算输出过程中，在结构中的体现为隐层间有节点相连。循环神经网络可以看作是一个简单神经网络在不同时间上的叠加，每个神经网络保留自身状态并传递给下一时刻的神经网络，循环神经网络的结构如图 4.1 所示。




图 4.1 循环神经网络结构

图中等号左边的网络可以看作是右边多个神经网络的叠加，每个网络主要由输入层、隐含层和输出层组成。在每一次的预测之后，网络会将预测值与真实值

进行比对,得到一个误差值对网络的权重进行更新,当计算出每个时刻的误差后,总的误差就表示为各个时刻误差之和,得到总误差后需要计算误差关于各个权重的梯度,然后利用梯度下降法在学习的过程中不断地更新参数。

RNN 虽然可以用来处理时序信号,但是其网络结构决定了其网络记忆中影响最深的仍然是最新时刻输入的数据。早期输入的信号在网络中保留的记忆变得越来越少,各个的更新使得其对于网络的影响越来越低,这导致了 RNN 的预测出现偏差。对于某些时间跨度较长的复杂时序信号,对早期重要信息的遗忘是 RNN 面临的问题。因此,RNN 的缺点是无法处理由于梯度消失或梯度爆炸问题而导致的长期依赖性<sup>[48]</sup>。为了解决这一问题,许多研究对于隐藏层的结构进行改进,通过调整隐藏层来避免这一梯度消失问题。此时人们针对 RNN 短时记忆问题设计出了长短时记忆网络方法 (LSTM, long short-term memory),通过将门函数引入细胞结构,LSTM 可以很好地处理长期依赖性的问题<sup>[49]</sup>,LSTM 的结构如图 4.2 所示。




图 4.2 LSTM 网络结构

相较于 RNN, LSTM 新增了一个细胞状态  $C_t$ 。当在  $t$  时刻时, LSTM 的输入包括系统输入  $x_t$ , 上一时刻的细胞状态  $C_{t-1}$ , 隐层的状态  $h_{t-1}$ 。输出包括当前的细胞状态  $C_t$ , 网络输出  $h_t$ , 两者在初始阶段通常设置为 0。LSTM 网络隐层中的门结构能够更新其内部细胞状态的信息,使得信息可以随着时间不断地传递,实现长期的记忆。LSTM 网络中的门结构包含遗忘门,输入门和输出门。

### (1) 遗忘门

遗忘门的作用是控制网络是否遗忘信息,即一定概率或一定条件下控制是否遗忘上一时刻细胞隐藏层的状态,遗忘门的结构如图 4.3 所示。






图 4.3 遗忘门

$f_t$  的计算公式为：

$$f_t = \sigma(W_f * [h_{t-1}, x_t] + b_f)$$

得出输出  $f_t$  后， $f_t$  会逐位地与前一个时刻细胞状态  $C_{t-1}$  相乘，在这个过程中  $C_{t-1}$  的一部分信息就会被舍弃，一部分信息被保留，因此能够对记忆进行筛选。

## (2) 输入门

输入门的作用是在遗忘门对细胞信息进行更新后，输入当前时刻的值再次对细胞状态进行更新，输入门的结构如图 4.4 所示。




图 4.4 输入门

输入门分为两个部分，一个部分  $C_t$  表示新的输入带来的新的信息，另一个部分  $i_t$  的结构与遗忘门相似，用于决定新的信息要保留哪一些部分。以  $i_t$  为例，其计算公式分别为：

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i)$$

对这两个部分进行运算后，需要对当前的细胞状态  $C_t$  进行更新，经过遗忘门和输入门后，当前新的细胞状态就等于先前的细胞状态经过遗忘门与选择性的保留当前的输入信息之和。

### (3) 输出门

输出门是在细胞状态更新后，决定网络的输出值，输出门结构如图 4.5 所示。




图 4.5 输出门

输出值计算公式为：

$$o_t = \sigma(W_o[h_{t-1}, x_t] + b_o)$$
$$h_t = o_t * \tanh(C_t)$$

最终的输出由当前的细胞状态、输入以及上一时刻隐层状态共同决定。上述式子中  $\sigma$  为 sigmoid 激活函数，用于在各个门上，区间为 (0, 1)，决定了更新或遗忘的概率值。tanh 激活函数则用在各个状态和输出之上，对数据进行处理，由于其输出值在  $[-1, 1]$  区间，目的是把输出均值调为 0。

目前 LSTM 已被广泛用于与序列数据相关的故障研究领域，文献[50]中提出将双向 LSTM 用于雷达的状态监测并实现了故障预测；文献[51]中将 LSTM 和统计分析法相结合实现了航空发动机轴承的故障预测；文献[52]中为了解决模拟电路故障带来的严重后果，提出使用深度 LSTM 跟踪故障发生前的状态并有效地实现了预测。

## 4.2 基于 LSTM 神经网络的故障预测能力分析

### (1) 实验数据选取和数据处理

本节实验选用轴承数据中的一种故障数据进行预测，该故障数据的故障位置在轴承内圈，故障直径为 0.007 英寸，负载情况为 3 马赫。该故障数据为时序信号，适用于 LSTM 神经网络进行故障预测分析。

对选用的故障数据进行预处理，本实验预测目的是通过过去的 40 个时刻的值，来对下 1 个时刻的值进行预测，于是用滑动窗口采样的方式，对初始数据进

行处理。窗口大小设置为 40，每个样本包含 40 个数据点，窗口滑动的步长为 20，采用重叠采样的方式增大数据集，窗口滑动 960 次，得到 960 个样本，并对每个样本进行归一化。将每个样本的下一时刻数据作为样本的标签，以便在训练过程中将预测值和真实值比对。同时为了避免测试集中出现训练集中的数据，将样本按时间顺序分为 900 个训练样本和 60 个测试样本后，在两个数据集内部随机打乱样本顺序，用于网络训练和验证。

## (2) LSTM 神经网络模型设计和测试结果

本节实验使用 keras 深度学习框架对 LSTM 结构进行设计，LSTM 网络结构如图 4.6 所示。

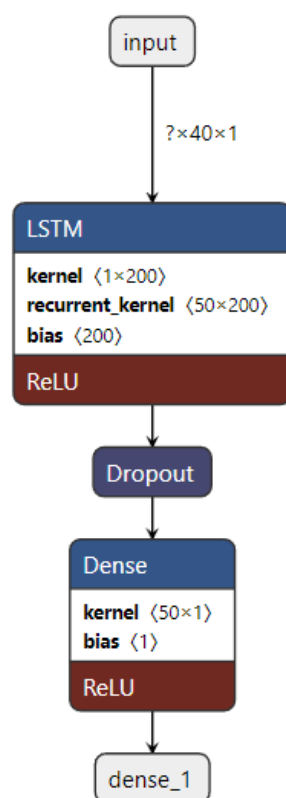


图 4.6 LSTM 网络结构

本节设计一层 LSTM 层，隐藏层细胞状态维度设为 50，在全连接层前加入 dropout 抑制过拟合，dropout 比例为 50%。激活函数选用 ReLu 函数，损失函数算法使用均方误差算法（MSE），优化方式采用 Adam 优化器。由于本实验的目的是通过 40 个先前值预测 1 个未来值，因此输入数据格式中的时间步长设为 40，特征为 1，指每个时刻有一个数据值。最后经过一个全连接层输出 1 个预测值，与真实值对比计算误差来对网络进行训练更新参数。

本节首先选用 900 个训练集样本对网络进行训练，再用 60 个测试集样本验证效果，将 60 个样本的预测值与 60 个真实值比对，得到两者之间的均方根误差，用于评价模型的预测有效性，预测结果如图 4.7 所示。




图 4.7 预测值与真实值对比图

图中纵轴表示预测的值大小，横轴表示第几个测试样本，红色折线表示真实值，绿色折线表示预测值，预测值与真实值的均方根误差为 0.0085288。由图中可以看出该模型具有优秀的拟合效果，整体偏差值很小，仅在少数测试中出现了误差明显的情况，本实验验证了 LSTM 对于时序信号能够较好地整合先前的记忆用于预测，且模型的预测准确率很高。

### 4.3 基于 LSTM 神经网络和卷积神经网络的故障预测能力分析

为了提高预测的准确率，考虑将卷积神经网络和 LSTM 相结合。卷积神经网络能够提取数据中潜在的局部特征，而 LSTM 能够提取长时的特征，因此将这两种网络相结合的研究近来一直受到关注，文献[53]中将两者结合创建了一种交通碰撞风险预测模型；文献[54]将两者结合实现了电能消耗的完美预测。本节实验尝试将一维卷积神经网络和 LSTM 神经网络相结合，实现故障预测的功能，并验证效果比单层 LSTM 神经网络更好。

本节实验选用与上一节实验相同的数据集，目的是使用 40 个先前值对下一时刻值进行预测。先使用卷积神经网络对数据进行特征处理，再根据 LSTM 网

络需要的数据格式，通过全连接层进行输出。输出数据进入单层 LSTM 网络中，得到数据的预测值，整体网络框架如图 4.8 所示。

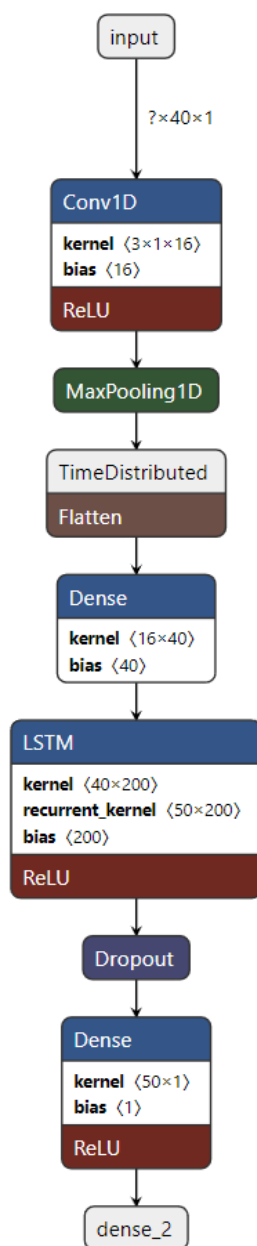


图 4.8 CNN+LSTM 网络结构

一维卷积网络层卷积核大小设置为 3，卷积核数量为 16，池化层采用最大池化，之后再经过全连接层输出 40 维的数据，用于投入 LSTM 网络中，满足用 40 个值预测下一个值的要求。LSTM 网络细胞状态数设置与上一小节相同，最终的预测结果如图 4.9 所示。




图 4.9 预测值与真实值对比图

图中纵轴表示预测的值大小，横轴表示第几个测试样本，红色折线表示真实值，绿色折线表示预测值。60 次测试后，预测值与真实值的均方根误差为：0.0075041，单独使用 LSTM 与 LSTM 和 CNN 相结合的对比结果如表 4.1 所示。

网络结构	LSTM	LSTM+CNN
均方根误差	0.0085288	0.0075041

表 4.1 LSTM 与 CNN+LSTM 均方根误差对比

由图和数据可看出，两种方法的故障预测效果都很精准，均低于 1% 的误差。但图中可以看出基于 LSTM 和 CNN 相结合的方法较于基于 LSTM 的方法，模型拟合的程度更高，均方根误差更小，并且对于单独使用 LSTM 实验中某一些偏差较大的值，结合了 CNN 的特征提取效果后预测的准确率有了明显的改善，图中仅能看出存在两个值误差较明显，预测的整体稳定性得到了上升，因此 LSTM+CNN 的方法在故障预测中的效果更好。

## 4.4 本章小结

本章基于循环神经网络处理时序信号的思想，搭建了两种神经网络模型进行故障预测。LSTM 是一种有效的循环神经网络，能够利用长期的记忆进行预测。本章设计了 LSTM 神经网络模型和 LSTM 与 CNN 相结合的神经网络模型，并通过使用相同的数据集测试，验证了两者均能输出高精度的故障预测结果，并且

---

LSTM 与 CNN 结合的模型预测的误差值更小，效果更好，因而对于故障的早期预警和定位，以及设备的剩余有效寿命的预测实现变为可能，解决了在故障诊断中需要对故障采取预防措施的问题。

---

## 第 5 章 总结与展望

### 5.1 主要工作总结

故障诊断不仅是保证设备运行安全稳定的基础,而且是保障各类工业工作人员健康安全的关键。故障诊断技术已成为一项重要的工业技术,其防止大规模故障发生的作用有利于环境和经济的可持续发展。本文围绕故障诊断问题,提出了多个基于深度学习的诊断方法,根据所选数据集设计了多个神经网络模型,主要工作如下:

(1) 针对轴承故障分类问题,采用深度学习中的卷积神经网络作为故障特征提取工具,有效地对故障进行分类。根据故障信号数据的形式,分别基于一维、AlexNet 和 GoogleNet 卷积神经网络搭建三种卷积神经网络模型,将三种模型进行故障分类验证实验,得出三者均有高分类精度,基于 GoogleNet 模型效果最优的结果。同时对 inception 模块的作用进行了讨论,得出基于 GoogleNet 模型增加了 inception 的层数后,分类的准确率得到了提升。

(2) 针对故障分类中特征提取问题,采用将传统的信号分析方法预处理数据与深度学习结合的方式,有效地提取了故障的特征,提高了故障分类的准确率。利用小波包分解法,将原始的数据进行多层分解,提取数据细微的特征,再基于卷积神经网络 AlexNet 和 GoogleNet,搭建两个网络框架。通过对原始数据和小波包处理的数据进行测试对比,验证了信号分析方法有利于故障分类中进行特征提取。

(3) 针对传统故障预测欠佳问题,基于时序信号的特点,采用循环神经网络对故障进行预测。构建了 LSTM 神经网络模型对轴承状态进行预测,并针对特征提取问题,提出将 CNN 与 LSTM 网络结合的方式,即使用一维卷积神经网络提取特征后放入 LSTM 中进行预测,验证后得到了比单独用 LSTM 更高的预测精度。



---

## 5.2 未来工作展望

本文对基于深度学习的故障诊断的方法进行了初步的研究,设计了多个有效的故障分类和预测模型,但对于实际应用中具有复杂性、相关性、不确定性等特性的大规模工业系统<sup>[55]</sup>仍存在很多问题值得进一步地探讨,主要包括:

(1) 对于故障分类的准确率问题,卷积神经网络的网络框架设计和参数选择是关键性因素。但还可针对模型的梯度下降过程,基于数学理论改进梯度优化算法,设计更优秀的优化器。同时可以采取更多的传统信号分析方法结合神经网络的方式,提高故障特征提取能力,为故障诊断提供更有效的方案。

(2) 故障预测仅停留在对于时序信号的未来状态预测,可在此基础上研究对于早期的故障定位以及对于设备剩余有效寿命的预测,这也是智能故障预测的重要研究方向,在未来有着广泛的应用场景。

(3) 大规模工业系统中的数据不仅数量巨大而且来源和类型不统一<sup>[57]</sup>,同时数据的分布不均匀,存在大量的正常数据和少量的故障数据,而深度学习模型的训练需要大量的故障数据<sup>[56]</sup>,因此开发出能够适应工业数据特点并便于训练的模型具有非常大的实际意义。

---

## 致 谢

时光荏苒，转眼间大学本科四年已经走到尽头，我们即将迎来人生的又一个重要拐点。在这四年里我收获了很多，无论是书本知识的积累，还是为人处世的道理，亦或是身体素质的增长，都离不开这四年里关心和帮助过我的人。

首先，需要感谢我的指导老师修贤超老师。他待人和蔼可亲，对待学术问题认真严谨，为我们精心设置了研究课题，分享了各类学术资料，在我遇到研究难点时耐心地解答，使我的课题能够顺利进行。修老师还多次为我修改文章中的不足之处并给出指导性的建议，最终帮助我完成了毕业论文的撰写。

其次，我要感谢在大学四年中每一位给我授过课的老师 and 帮助过我的辅导员，是他们孜孜不倦地讲解知识，针对性地设定任务，让我能够吸收到专业知识，潜移默化地拓宽我的视野，提升我的思维。或是关心我的身心健康，提供各种生活帮助，排解我的烦恼。

再次，我要感谢我大学四年身边的朋友们，是他们在这四年里和我分享快乐，分担烦恼，给我带来了各种帮助，让我感受到来自五湖四海的朋友间纯真的友谊。无论今后走到哪里，友谊都不会改变。

最后，我要感谢我的父母，是他们将我从小抚养长大，在背后源源不断地给我提供物质保障和心理关怀，无怨无悔，永远给予我支持和鼓励，让我能够有动力不断地前进。

最终我还要再次向我的老师们、同学们和家人们表达衷心的感谢，在未来我会带着老师的教诲和家人们的期盼，在求学的道路上继续努力进取，勇敢前行，最后祝愿各位前程似锦，不忘初心！

---

## 参考文献

- [1]. 赵鹏飞, 贺阿红, 姚颖. 河北省城市重大工业安全事故危害及防控策略研究. 河北工程大学管理工程与商学院. 2020, 41 (08) :31-35.
- [2]. Y Lei, B Yang, X Jiang, et al. Applications of machine learning to machine fault diagnosis: A review and roadmap[J]. Mechanical Systems and Signal Processing, April 2020, 138:106587.
- [3]. Arunthavanathan R, Khan F, Ahmed S, et al. An analysis of process fault diagnosis methods from safety perspectives[J]. Computers & Chemical Engineering, 2021,145:107197.
- [4]. 张士强. 基于深度学习的故障诊断技术研究[D]. 哈尔滨工业大学, 2018.
- [5]. S. Zhang, S. Zhang, and B. Wang. Deep learning algorithms for bearing fault diagnostics—A comprehensive review[J]. IEEE Access, 2020,8:29857-29881.
- [6]. 马杰, 张龙飞, 彭俏等. 基于分层符号有向图的二回路系统故障诊断[J]. 兵器装备工程学报. 2020, 41 (08) , 176-181.
- [7]. 董鹏乐. 基于故障树的铁路通信光缆故障诊断系统设计[J]. 自动化与仪器仪表. 2022, 2:190-194.
- [8]. Han Zhang, Li Yanling, Zhao Zepeng. An online safety monitoring system of hydropower station based on expert system[J]. Energy Reports. 2022, 8(S4):1552-1567.
- [9]. Lu Yunsong, Wang Fuli, Jia Mengxing. Centrifugal compressor fault diagnosis based on qualitative simulation and thermal parameters. Mechanical Systems and Signal Processing[M].2016,81(15): 259-273.
- [10]. 谈娟. 基于解析模型的飞控系统故障诊断技术研究[D]. 南京航空航天大学. 2020, 5-12.
- [11]. 徐彪, 尹项根, 张哲. 电网故障诊断的分阶段解析模型[J]. 电工技术学报. 2018, 33 (17) :4113-4122.
- [12]. 周志华. 机器学习[M]. 清华大学出版社. 2016:121-139, 298-300.
- [13]. Yan X, Jia M. A novel optimized SVM classification algorithm with

- 
- multi-domain feature and its application to fault diagnosis of rolling bearing[J]. *Neurocomputing*, 2018, 313: 47-64.
- [14]. Delpha C, Diallo D, Al Samrout H, et al. Multiple incipient fault diagnosis in three-phase electrical systems using multivariate statistical signal processing[J]. *Engineering Applications of Artificial Intelligence*, 2018, 73: 68-79.
- [15]. Manel Rhif, Ali Ben Abbes, Imed Riadh Farah, et al. Wavelet transform application for/in non-stationary time-series analysis: A Review.[J], *Sci*. 2019, 9(7), 1345.
- [16]. Adly A R, Aleem S H E A, Elsadd M A, et al. Wavelet packet transform applied to a series-compensated line: a novel scheme for fault identification[J]. *Measurement*, 2020, 151: 107156.
- [17]. Zhao G, Zhang G, Ge Q, et al. Research advances in fault diagnosis and prognostic based on deep learning[C]//2016 Prognostics and system health management conference (PHM-Chengdu). IEEE, 2016: 1-6.
- [18]. 安晶, 艾萍, 徐森等. 一种基于一维卷积神经网络的旋转机械智能故障诊断方法[J]. *南京大学学报(自然科学版)*, 2019, 55(1): 133-135.
- [19]. Gong D, Liu L, Le V, et al. Memorizing normality to detect anomaly: Memory-augmented deep autoencoder for unsupervised anomaly detection[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2019: 1705-1714.
- [20]. Shan Pang, Xinyi Yang, Xiaofeng Zhang. Aero engine component fault diagnosis using multi-hidden-layer extreme learning machine with optimized structure[J]. *Int J of Aerospace Engineering*, 2016, 1329561.
- [21]. Ahmad Shaheryar, Xucheng Yin, Hong-Wei Hao, et al. A de-noising based auto-associative model for robust sensor monitoring in nuclear power plants[J]. *Science and Technology of Nuclear Installations*, 2016, 9746948.
- [22]. Hongmei Liu, Lianfeng Li, Jian Ma. Rolling bearing fault diagnosis based on STFT-deep learning and sound signals[J]. *Shock and Vibration*, 2016, 6127479.
- [23]. Utkin L V, Zaborovskii V S, Popov S G. Detection of anomalous behavior in a

- 
- robot system based on deep learning elements[J]. Automatic Control and Computer Sciences, 2016, 50(8): 726-733.
- [24]. Yanhe Guo; Shuang Wang ; Chenqiong Gao. Wishart RBM based DBN for polarimetric synthetic radar data classification[J]. IEEE International Geoscience and Remote Sensing Symposium. July, 2015.
- [25]. Van Tung Tran, Failsal AlThobiani, Andrew Ball. An approach to fault diagnosis of reciprocating compressor valves using Teager-Kaiser energy operator and deep belief networks[J]. Expert Systems with Applications, 2014, 41(9): 4113- 4122.
- [26]. Prasanna Tamilselvan, Pingfeng Wang. Failure diagnosis using deep belief learning based health state classification[J]. Reliability Engineering and System Safety, 2013, 115(7): 124-135.
- [27]. Chuan Li, René-Vinicio Sánchez, Grover Zurita, et al. Multimodal deep support vector classification with homologous features and its application to gearbox fault diagnosis[J]. Neurocomputing, 2015, 168(C): 119-127.
- [28]. Peng H-K, Marculescu R. Multi-scale compositionality: Identifying the compositional structures of social dynamics using deep learning[J]. PLOS one, 2015, 10(4): e0118309.
- [29]. Y. Huang, C. -H. Chen and C. -J. Huang. Motor fault detection and feature extraction using RNN-based variational autoencoder. IEEE Access. 2019, 7: 139086-139096
- [30]. Zhang C, Lim P, Qin A K, et al. Multiobjective deep belief networks ensemble for remaining useful life estimation in prognostics[J]. IEEE transactions on neural networks and learning systems, 2016, 28(10): 2306-2318.
- [31]. Xia T, Song Y, Zheng Y, et al. An ensemble framework based on convolutional bi-directional LSTM with multiple time windows for remaining useful life estimation[J]. Computers in Industry, 2020, 115: 103182.
- [32]. Hasani R M, Wang G, Grosu R. An automated auto-encoder correlation-based health-monitoring and prognostic method for machine bearings[J]. arXiv preprint arXiv:1703.06272, 2017.

- 
- [33]. Wang J, Zhang C. Software reliability prediction using a deep learning model based on the RNN encoder–decoder[J]. *Reliability Engineering & System Safety*, 2018, 170: 73-82.
- [34]. Gavrishchaka V, Yang Z, Miao R, et al. Advantages of hybrid deep learning frameworks in applications with limited data[J]. *International Journal of Machine Learning and Computing*, 2018, 8(6): 549-558.
- [35]. Ahlawat S, Choudhary A, Nayyar A, et al. Improved handwritten digit recognition using convolutional neural networks (CNN)[J]. *Sensors*, 2020, 20(12): 3344.
- [36]. Totakura V, Vuribindi B R, Reddy E M. Improved safety of self-driving car using voice recognition through CNN[C]//IOP conference series: materials science and engineering. IOP Publishing, 2021, 1022(1): 012079.
- [37]. Peng D, Liu Z, Wang H, et al. A novel deeper one-dimensional CNN with residual learning for fault diagnosis of wheelset bearings in high-speed trains[J]. *Ieee Access*, 2018, 7: 10278-10293.
- [38]. ZhiQiang Chen, Chuan Li, Rene-Vinicio Sanchez. Gearbox fault identification and classification with convolutional neural networks[J]. *Shock and Vibration*, 2015, 390134.
- [39]. 王昕. 梯度下降及优化算法研究综述[J]. *电脑知识技术*. 2022, 18(8): 71–73.
- [40]. Eren, L., Ince, T. & Kiranyaz, S. A generic intelligent bearing fault diagnosis system using compact adaptive 1D CNN Classifier. *J Sign Process Syst* 91, 2019, 179–189.
- [41]. Jing L, Zhao M, Li P, et al. A convolutional neural network based feature learning and fault diagnosis method for the condition monitoring of gearbox[J]. *Measurement*, 2017, 111: 1-10.
- [42]. Jana G C, Sharma R, Agrawal A. A 1D-CNN-spectrogram based approach for seizure detection from EEG signal[J]. *Procedia Computer Science*, 2020, 167: 403-412.
- [43]. H.C. Shin, H.R. Roth, M. Gao, L. Lu, Z. Xu, I. Nogues, et al., Deep convolutional neural networks for computer-aided detection: CNN architectures dataset

- 
- characteristics and transfer learning. *IEEE Transactions on Medical Imaging*[J], 2016, 35(5): 1285-1298.
- [44]. Al-Qizwini M, Barjasteh I, Al-Qassab H, et al. Deep learning algorithm for autonomous driving using googlenet[C]//2017 IEEE Intelligent Vehicles Symposium (IV). IEEE, 2017: 89-96.
- [45]. Chakraborty S, Shamrat F M J M, Afrin S, et al. Industrial fault detection using transfer learning models[C]//2021 2nd International Conference on Smart Electronics and Communication (ICOSEC). IEEE, 2021: 1-6.
- [46]. Han Y, Tang B, Deng L. Multi-level wavelet packet fusion in dynamic ensemble convolutional neural network for fault diagnosis[J]. *Measurement*, 2018, 127: 246-255.
- [47]. 刘建伟, 宋志妍. 循环神经网络研究综述[J/OL]. *控制与决策* 2022, 1-17.
- [48]. Shewalkar A. Performance evaluation of deep neural networks applied to speech recognition: RNN, LSTM and GRU[J]. *Journal of Artificial Intelligence and Soft Computing Research*, 2019, 9(4): 235-245.
- [49]. Yong Yu, Xiaosheng Si, Changhua Hu, Jianxun Zhang; A review of recurrent neural networks: LSTM cells and network architectures. *Neural Comput* 2019; 31 (7): 1235–1270.
- [50]. 倪祥龙, 石长安, 麻曰亮. 基于 Bi-LSTM 的电子装备故障预测方法研究[J/OL]. *航空兵器* 2022, 1-9.
- [51]. Liu J, Pan C, Lei F, et al. Fault prediction of bearings based on LSTM and statistical process analysis[J]. *Reliability Engineering & System Safety*, 2021, 214: 107646.
- [52]. Binu D, Kariyappa B S. Rider-deep-LSTM network for hybrid distance score-based fault prediction in analog circuits[J]. *IEEE Transactions on Industrial Electronics*, 2020, 68(10): 10097-10106.
- [53]. Li P, Abdel-Aty M, Yuan J. Real-time crash risk prediction on arterials based on LSTM-CNN[J]. *Accident Analysis & Prevention*, 2020, 135: 105371.
- [54]. Kim T Y, Cho S B. Predicting residential energy consumption using CNN-LSTM

- 
- neural networks[J]. Energy, 2019, 182: 72-81.
- [55]. 段艳杰, 吕宜生, 张杰等. 深度学习在控制领域的研究现状与展望[J]. 自动化学报, 2016, 42(5): 643-654.
- [56]. Mohammed Alawad, Mingjie Lin. Stochastic-based deep convolutional networks with reconfigurable logic fabric[J]. IEEE Trans on Multi-Scale Computing Systems, 2016, 2(4): 242-256.
- [57]. 刘强, 秦泗钊. 过程工业大数据建模研究展望[J]. 自动化学报, 2016, 42(2): 161-171.